



UNIVERSIDAD
DE GRANADA

ETS Ingeniería Informática y de Telecomunicación

MÁSTER EN CIENCIA DE DATOS E INGENIERÍA DE COMPUTADORES

TRABAJO DE FIN DE MÁSTER

Mejora de la Explicabilidad en Modelos de Clasificación de Lesiones Cancerosas en Biopsias de Próstata mediante Técnicas XAI.

Presentado por:

Carlos Lara Casanova

Tutor:

Francisco Herrera Triguero

Departamento de Ciencias de la Computación e Inteligencia Artificial

Mentor:

Iván Sevillano-García

Departamento de Ciencias de la Computación e Inteligencia Artificial

Curso académico 2024-2025 Convocatoria extraordinaria

3 de septiembre de 2025

Mejora de la Explicabilidad en Modelos de Clasificación de Lesiones Cancerosas en Biopsias de Próstata mediante Técnicas XAI.

Carlos Lara Casanova

Carlos Lara Casanova *Mejora de la Explicabilidad en Modelos de Clasificación de Lesiones Cancerosas en Biopsias de Próstata mediante Técnicas XAI..*

Trabajo de fin de Máster. Curso académico 2024-2025.

**Responsables de
tutorización**

Francisco Herrera Triguero
*Departamento de Ciencias de la
Computación e Inteligencia Artificial*

Iván Sevillano-García
*Departamento de Ciencias de la
Computación e Inteligencia Artificial*

Máster en Ciencia de
Datos e Ingeniería de
Computadores

ETS Ingeniería
Informática y de
Telecomunicación

Universidad de Granada

DECLARACIÓN DE ORIGINALIDAD

D./Dña. Carlos Lara Casanova

Declaro explícitamente que el trabajo presentado como Trabajo de Fin de Máster (TFM), correspondiente al curso académico 2024-2025, es original, entendido esto en el sentido de que no he utilizado para la elaboración del trabajo fuentes sin citarlas debidamente.

En Granada a 3 de septiembre de 2025

Fdo: Carlos Lara Casanova

Índice general

Agradecimientos	V
Summary	VII
Resumen	IX
1 Introducción	1
1.1 Objetivos	4
1.2 Planificación	4
2 Fundamentos teóricos	7
2.1 Aprendizaje automático	7
2.1.1 Problema de clasificación	8
2.1.2 Problema de regresión	8
2.1.3 Optimización	9
2.1.4 Sobreentrenamiento	11
2.2 Deep Learning	12
2.2.1 Redes neuronales artificiales	12
2.2.2 Redes neuronales convolucionales	16
2.3 XAI	20
2.3.1 Explicaciones lineales locales y LIME	22
2.3.2 Métricas ReVEL	23
2.3.3 Regularización X-Shield	28
3 Estado del arte	31
4 Métodos	39
4.1 EfficientNet	39
4.2 XSHIELD	40
4.3 Métodos propuestos	40
4.3.1 FX-Shield	40
4.3.2 FR-Shield	44
4.3.3 H-Shield	44
	III

Índice general

4.4 Implementación	44
5 Experimentos	49
5.1 Datos empleados	49
5.2 Experimentación	53
5.2.1 Separación de datos	53
5.2.2 Elección de hiperparámetros	54
5.3 Métricas	56
5.4 Resultados	57
5.4.1 Entrenamiento y accuracy	58
5.4.2 Métricas REVEL	63
5.5 Discusión	66
6 Conclusiones	67
Bibliografía	69

Agradecimientos

Gracias a Francisco e Iván por brindarme la oportunidad de trabajar con ellos y guiarme durante la realización de este trabajo. Gracias a mi familia por apoyarme durante el tiempo que me llevó desarrollar este trabajo.

Summary

KEYWORDS: neural networks, xai, explainable ai, prediction, explainability, artificial intelligence, machine learning, computer vision, deep learning, prostate cancer, gleason score, gleason groups.

This Master’s Thesis addresses the problem of improving interpretability for classification models for cancerous lesions in prostate biopsies. Prostate cancer is the second most common type of cancer in men worldwide. Early diagnosis is crucial to reducing mortality rates. Prostate biopsy is the procedure used to diagnose cancer when it is suspected. In recent years, the growing use of Artificial Intelligence (AI) techniques in the field of healthcare has led to significant improvements in the diagnosis of prostate cancer.

On the other hand, Explainable Artificial Intelligence (XAI) is a field of study that seeks to improve the interpretability of Machine Learning (ML) models. Its use is especially relevant in fields such as medicine, where decision-making has an impact on people’s lives. For this work, we propose applying different XAI techniques to improve the interpretability of the model.

To do this, we first explain key concepts for understanding it and study the state of the art of the different aspects relevant to our task. These are image classification models, XAI methods for producing explanations, metrics for measuring the quality of explanations, and XAI regularization methods.

For image classification, we used the EfficientNet convolutional network, which is state-of-the-art in terms of precision relative to the number of model parameters. To produce explanations for our model, we use the LIME method, which produces local and linear explanations based on the model input. This allows us to measure the quality of the explanations generated quantitatively using REVEL metrics, which measure different aspects of local and linear explanations.

Based on the state-of-the-art XAI regularization method X-SHIELD, we propose three novel XAI regularization methods: FX-SHIELD, FR-SHIELD, and H-SHIELD. Regularization methods add a penalty to the model during training. The first, FX-SHIELD,

adds a penalty as the model's prediction varies by removing the least important features extracted by the convolutional part of the model. FR-SHIELD does the same as FX-SHIELD but removes random features without considering their importance. Finally, H-SHIELD combines FX-SHIELD and X-SHIELD to try to combine the improvements introduced by each proposal.

For training the model with the different methods, a dataset of 126,109 images measuring 224×224 pixels is available, corresponding to prostate biopsy patches. Each of these images is labeled with one of fourteen possibilities. Each possible label represents different types of prostate tissue according to their morphology and whether they are malignant or benign. This will be the class that the model we train predicts for an input patch. We have divided the dataset into 113,491 images (90%) to train the model and 12,618 (10%) to test the classification performance of the models.

The results obtained show that the X-SHIELD and H-SHIELD methods achieve the best accuracy in validation and testing, surpassing the baseline by 0.7% and 0.6%, respectively. In contrast, FX-SHIELD and FR-SHIELD manage to maintain the accuracy of the base model without using regularization. However, FX-SHIELD clearly stands out from the others in terms of the quality of its explanations, achieving better results in two of the five REVEL metrics and obtaining the same results as the rest in another two of the five. The Bayesian tests used confirm that FX-SHIELD outperforms X-SHIELD and H-SHIELD in prescriptivity and conciseness (although the latter is not always significant), and significantly improves on FR-SHIELD in conciseness. In addition, all variants obtain similar values in local fidelity and local concordance. Therefore, although X-SHIELD achieves the best accuracy, FX-SHIELD offers the highest quality explanations, which is crucial in applications where interpretability is a priority.

Resumen

PALABRAS CLAVE: redes neuronales, xai, ia explicable, clasificación, explicabilidad, inteligencia artificial, aprendizaje automático, visión por computador, aprendizaje profundo, cáncer de próstata, gleason score, gleason groups.

Este TFM ocupa el problema de mejorar la interpretabilidad para modelos de clasificación de lesiones cancerosas en biopsias de próstata. El cáncer de próstata es el segundo tipo de cáncer más frecuente en varones a nivel mundial. Un diagnóstico temprano de este es crucial para reducir la mortalidad del mismo. La biopsia de próstata es el procedimiento utilizado para el diagnóstico del mismo en caso de sospecha. En los últimos años el creciente uso de técnicas de Inteligencia Artificial (IA) en el campo de la salud ha collevado mejoras significativas en el diagnóstico del cáncer de próstata.

Por otro lado, la Inteligencia Artificial Explicable (XAI) es un campo de estudio que busca mejorar la interpretabilidad de los modelos de Machine Learning (ML). El uso de esta es especialmente importante en campos como la medicina, donde la toma de decisiones repercute en la vida de personas. Para este trabajo proponemos aplicar distintas técnicas XAI para mejorar la interpretabilidad del modelo.

Para la realización de este primero explicamos conceptos claves para entenderlo y estudiamos el estado del arte de los distintos aspectos relevantes a nuestra tarea. Estos son modelos de clasificación de imágenes, métodos XAI para producción de explicaciones, métricas para medir la calidad explicaciones y métodos de regularización XAI.

Para clasificación de imágenes hemos utilizado la red convolucional EfficientNet, que es el estado del arte en poder de clasificación respecto al número de parámetros del modelo. Para producción de las explicaciones de nuestro modelo hacemos uso del método LIME que produce explicaciones locales y lineales a partir de la entrada al modelo. Esto nos permite medir la calidad de las explicaciones generadas de forma cuantitativa con las métricas REVEL, que miden distintos aspectos de explicaciones locales y lineales.

Partiendo del método X-SHIELD de regularización XAI, que representa el estado del arte, proponemos 3 métodos novedosos de regularización XAI FX-SHIELD, FR-SHIELD y H-SHIELD. Los métodos de regularización añaden una penalización al modelo durante el entrenamiento. El primero, FX-SHIELD, añade una penalización según varíe la predicción del modelo al quitar las características menos importantes extraídas por la parte convolucional del modelo. FR-SHIELD por su parte hace lo mismo que FX-SHIELD pero quitando características aleatorias sin tener en cuenta su importancia. Finalmente H-SHIELD combina FX-SHIELD y X-SHIELD para intentar combinar las mejoras introducidas por cada propuesta.

Para el entrenamiento del modelo con los distintos métodos se dispone de un conjunto de datos de 126.109 imágenes de tamaño 224×224 correspondientes a parches de biopsias de próstata. Cada una de estas imágenes está etiquetada con una de catorce posibilidades. Cada posible etiqueta representa diferentes tipo de tejido prostático según la morfología de estas y si es tejido maligno o benigno. Esta será la clase que busca predecir el modelo que entrenamos para un parche de entrada. De estas hemos utilizado 113.491 imágenes (90 %) para entrenar el modelo y 12.618 (10 %) para evaluar el rendimiento en clasificación de los modelos.

Los resultados obtenidos muestran que los métodos X-SHIELD y H-SHIELD obtienen la mejor *accuracy* en validación y test, superando al baseline en un 0.7 % y 0.6 % respectivamente. En cambio, FX-SHIELD y FR-SHIELD consiguen mantener la *accuracy* del modelo base sin utilizar regularización. Sin embargo, FX-SHIELD destaca claramente en la calidad de las explicaciones sobre los demás, logrando mejores resultados en dos de las cinco métricas REVEL y obteniendo los mismo resultados que el resto en otras dos de las cinco. Los test bayesianos utilizados confirman que FX-SHIELD supera a X-SHIELD y H-SHIELD en *prescriptivity* y en *conciseness* (aunque esta última no siempre con significancia), y mejora significativamente a FR-SHIELD en *conciseness*. Además, todas las variantes obtienen valores similares en *local fidelity* y *local concordance*. Por tanto, aunque X-SHIELD logra la mejor precisión, FX-SHIELD ofrece las explicaciones de mayor calidad, lo que es crucial en aplicaciones donde la interpretabilidad es prioritaria.

1 Introducción

En 2020, el **cáncer de próstata**, (*Prostate Cancer*) fue el segundo tipo de cáncer más frecuente, y el quinto más mortal, en varones a nivel mundial (H y cols., 2021). Un diagnóstico temprano de este es crucial para reducir la mortalidad del mismo. A día de hoy, el diagnóstico del cáncer de próstata se basa en la realización de una biopsia de próstata en caso de sospecha, tras la evaluación inicial mediante pruebas como la medición del antígeno prostático específico o el examen rectal digital. Una biopsia de próstata es una prueba que consiste en la extracción de pequeños tejidos de la próstata para examinar posibles signos de cáncer (Ver Figura 1.1). El **Sistema de Puntuación de Gleason** es una calificación, en el rango de 2 a 10, que se da a biopsias de la próstata tras ser examinadas bajo un microscopio (Shah, 2024). Valores más altos indican cánceres más agresivos y de crecimiento más rápido. En 2014 la **Sociedad Internacional de Patología Urológica** (*International Society of Urological Pathology, ISUP*) propuso un nuevo sistema basado en la Puntuación de Gleason, que propone cinco grupos ordenados (Epstein, Amin, Reuter, y Humphrey, 2017). Los grupos de Gleason (GG) clasifican el cáncer de próstata en función de su agresividad de manera incremental. El GG1 corresponde a tumores de bajo grado (Gleason ≤ 6). El GG2 y el GG3 abarcan los de grado intermedio, ambos con Gleason 7, aunque el GG3 se considera más agresivo que el GG2. El GG4 incluye tumores de alto grado con Gleason 8, mientras que el GG5 representa la forma más agresiva, con puntuaciones Gleason de 9 o 10.




Figura 1.1: Tres imágenes correspondientes a tres biopsias distintas.

CAPÍTULO 1. INTRODUCCIÓN

El sistema de Gleason se ha consolidado como un factor determinante en el diagnóstico del cáncer de próstata (Rabaan y cols., 2022). La clasificación en grupos de Gleason permite estimar la agresividad de la enfermedad y estimar el riesgo de los tumores, lo que resulta esencial para elegir el tratamiento más adecuado. Pese a esto, el puntuar el grupo de Gleason consume mucho tiempo y, además, se basa en una gradación subjetiva, lo que genera una considerable variación en los resultados (Ikromjanov, Subrata, y cols., 2021). Por ello, el desarrollo de herramientas de apoyo a la decisión asistidas por computadora resulta fundamental para optimizar el tiempo y mejorar la precisión en el trabajo de los patólogos.

Además, un enfoque más cuantitativo, acompañado de la identificación de patrones más específicos, puede contribuir a diferenciar con mayor precisión entre distintas situaciones clínicas y, de esta manera, adaptar el diagnóstico, el plan de tratamiento y las condiciones de vigilancia. Por eso utilizaremos la distinción presentada en la Tabla 5.1.

Debido al éxito de los métodos de **Aprendizaje Automático** (*Machine Learning, ML*) en el campo de la medicina, la Patología Computacional se ha convertido en los últimos años en uno de los temas de aplicación de la **Inteligencia Artificial (IA)** utilizando imágenes histológicas. Algunos estudios han demostrado que la clasificación de Gleason con IA se traduce en un mejor pronóstico (Wulczyn, Nagpal, Symonds, y et al., 2021).

En el campo de la IA, la necesidad de asegurar transparencia y confiabilidad ha dado pie a acuñar el término de **Inteligencia Artificial eXplicable** (*eXplainable Artificial Intelligence, XAI*) (Longo y cols., 2024), que es un campo que busca mejorar la interpretabilidad de los modelos de AA. El uso de XAI es especialmente importante en ámbitos donde la toma de decisiones repercute directamente en la vida de las personas, como es el caso de la medicina. La Unión Europea ha propuesto una **regulación** para el uso de IA asistida en estos aspectos, entre ellos, que estos sistemas sean capaces de explicar sus decisiones de forma clara y comprensible.

Dentro del campo de la XAI, hay diferentes propuestas para la evaluación y la mejora de las explicaciones generadas. Por un lado, herramientas como **REVEL** (Sevillano-García, Luengo, y Herrera, 2023a) permiten analizar la calidad de las mismas de manera robusta. Por otro, enfoques como **X-SHIELD** (Sevillano-García, Luengo, y Herrera, 2023b) buscan mejorar las explicaciones mediante técnicas de regularización que aseguran el buen comportamiento de la generación de explicaciones. Aplicar estas técnicas en imagen médica puede ayudar a mejorar la interpretación de las personas profesionales de la salud de las decisiones de una IA que asista.

En este contexto este Trabajo de Fin de Máster trata de abarcar el problema de **construir un modelo de IA de clasificación para lesiones cancerosas en biopsias de próstata** y de la **mejora en interpretabilidad del modelo mediante técnicas de XAI**, ver la Figura 1.2. Para esto se vamos a utilizar las herramientas REVEL y XSHIELD, y propondremos posibles mejoras de XSHIELD.




Figura 1.2: En esta figura se resume el problema del TFM. Entrenaremos un modelo de clasificación de IA para la predicción de imágenes de biopsias de próstata. Produciremos explicaciones del modelo para datos de entrada. Mediremos la calidad de estas explicaciones con REVEL. Para mejorar la calidad de estas, entrenaremos los modelos con técnicas de regularización XAI.

El TFM se estructura del siguiente modo. En primer lugar vamos a introducir los fundamentos teóricos necesarios para el correcto entendimiento del trabajo realizado (Capítulo 2). Después se va a hacer un estudio del estado del arte (Capítulo 3). A continuación presentamos las propuestas de este TFM (Capítulo 4). En el Capítulo 5 se describe el conjunto de datos con el que trabajamos, los distintos experimentos que realizamos y discutimos los resultados. Finalmente en el Capítulo 6 se incluyen conclusiones y posibles trabajos futuros.

CAPÍTULO 1. INTRODUCCIÓN

1.1. Objetivos

El objetivo principal del TFM es el uso y la propuesta de técnicas de evaluación y mejora de explicaciones de modelos de clasificación de imágenes para detección de tejidos cancerosos en biopsias de próstata. Para el desarrollo del TFM, se divide el objetivo en distintos subobjetivos:

- Revisión del estado del arte.
- Estudio del código que implementa (Sevillano-García y cols., 2023a, 2023b) para su correcto entendimiento.
- Proposición de nuevos métodos XAI para mejora de explicaciones para modelos de explicación.
- Modificación del código para implementar dichas propuestas.
- Diseño de los experimentos a realizar e implementación de estos.
- Evaluación de los resultados y subsecuente discusión.

1.2. Planificación

Para la planificación del TFM se ha tenido en cuenta este son 12 créditos y que un crédito se corresponden con 25 horas de trabajo individual. Por lo tanto se estiman unas 225 horas de trabajo. Teniendo en cuenta que el estudiante se ha dedicado completamente, alrededor de 8 horas al día, el TFM pues empezó en Junio, esto se corresponden con unos dos meses de trabajo. Contando que se no se trabajan los fines de semana el trabajo total se queda en 7 semanas y media. Como no se pudieron dedicar las 8 horas todos los días, el trabajo finalmente se dividió en unas 10 semanas.

Para el desarrollo de software empleamos una metodología en cascada pues se trata de un proyecto con unos requisitos claros y que va a ser desarrollado únicamente por el alumno.

El trabajo requerido para realizar esta parte del TFM se ha dividido en cuatro fases:

- **Estudio del problema:** esta fase se corresponde con el estudio del problema que se intenta resolver en el trabajo así como del análisis del código del método del que partimos.

1.2. PLANIFICACIÓN

- **Diseño de métodos:** en esta fase se idean los distintos métodos con los que se intentará resolver el problema.
- **Implementación:** tiempo dedicado a la implementación en el código de los modelos.
- **Experimentación:** fase en la que se piensan y realizan los distintos experimentos sobre los modelos ideados.

Fase	Duración Semanas	Junio	Julio	Agosto
Estudio del problema	3.5			
Diseño de los métodos	2.5			
Implementación	2			
Experimentación	2			

Tabla 1.1: Planificación del proyecto.

En la Tabla 1.1 observamos la planificación inicial del trabajo del TFM, que fué la seguida para la realización del mismo.

Finalmente han hecho falta alrededor de 300 horas para la realización del TFM. Suponiendo que el sueldo de un investigador en una empresa de base tecnológica es de 20 euros por hora entonces se obtiene que el proyecto tiene un coste de 6000 euros de coste total.

2 Fundamentos teóricos

En este capítulo haremos un repaso de los fundamentos teóricos necesarios para poder entender el trabajo. En primer lugar presentamos el concepto de aprendizaje automático. A continuación hablaremos de qué es el deep learning y de redes neuronales. En particular destacamos las redes convolucionales que juegan un papel crucial en la clasificación de imágenes. Finalmente introducimos la inteligencia artificial explicable, el problema que tratan de resolver y algunos métodos XAI que utilizamos a lo largo del trabajo.

2.1. Aprendizaje automático

El **aprendizaje automático** (AA) o **machine learning** (ML) es una rama de la IA que se encarga del desarrollo de algoritmos que aprendan de datos o experiencias con el fin de mejorar su rendimiento en ciertas tareas (Alpaydin, 2020; Abu-Mostafa, Magdon-Ismail, y Lin, 2012; C. Bishop, 2006; Murphy, 2022). Estos algoritmos disponen de un **modelo** definido por ciertos parámetros, los cuales serán los que se aprendan a través del **entrenamiento** o **aprendizaje**.

Para saber a qué nos referimos cuando se habla de que el algoritmo “*aprende*” conviene destacar la siguiente definición proveniente de (Mitchell, 1997): “*Un programa se dice que aprende de una experiencia E con respecto a una clase de tareas T y a una medida de rendimiento T, si su rendimiento en las tareas en T, medido por P, mejora con la experiencia E.*”

El AA se utiliza habitualmente para abarcar problemas complejos que no se pueden o se saben resolver con algoritmos tradicionales diseñados por humanos. Además, se requiere tener datos de los que poder aprender, normalmente en grandes volúmenes. Algunos de los campos donde se utilizan el AA para resolver este tipo de problemas son el procesamiento de lenguaje natural, el reconocimiento del habla o la visión por computador, entre muchos otros.

Los algoritmos de AA se clasifican en distintos paradigmas dependiendo de los

CAPÍTULO 2. FUNDAMENTOS TEÓRICOS

datos o experiencia de la que se disponga. En este trabajo introducimos dos de los paradigmas principales, aunque existen otros paradigmas no relevantes para este trabajo: el **aprendizaje supervisado** y el **aprendizaje no supervisado** (Abu-Mostafa y cols., 2012; Goodfellow, Bengio, y Courville, 2016).

El aprendizaje supervisado hace referencia a los algoritmos de AA en los que se tiene un conjunto de datos agrupados en pares dato-**etiqueta**. La etiqueta se corresponde con la salida que se requiere del algoritmo de AA cuando tenga de entrada dicho dato. El término supervisado proviene de este último hecho, la etiqueta supervisa la salida del algoritmo para un dato. Un ejemplo típico de conjunto de datos de este tipo sería MNIST (Deng, 2012), un conjunto de imágenes de números escritos a mano y para cada imagen el número que está escrito en dicha imagen.

El aprendizaje no supervisado se refiere a los algoritmos de AA en los que se disponen de datos que no están etiquetados. En este tipo de algoritmos no se quiere aprender algo específico de los datos sino más bien encontrar patrones o estructurar los datos de entrada. Por ejemplo se dispone de distinta información relativa a libros (autor, título, número de páginas, etc) y el algoritmo categoriza los libros en distintas categorías, aunque no se sepa a qué se corresponde cada categoría.

Para este TFM el enfoque utilizado es el del aprendizaje supervisado dado que disponemos de datos etiquetados. En particular serán relevantes los dos siguientes problemas típicos de aprendizaje supervisado.

2.1.1. Problema de clasificación

Este problema trata de clasificar las entradas de un tipo concreto en un número de clases k . Es decir, para una entrada el programa deberá clasificar dicha entrada en una de las k clases. Por lo tanto el algoritmo produce una función $f : \mathbb{R}^n \rightarrow \{1, \dots, k\}$ que a cada entrada $\mathbf{x}$ le asocie una clase $y = f(\mathbf{x})$. Dicha función tratará de aproximar una función objetivo g que clasifique perfectamente todas las entradas.

Para este problema se disponen de una serie de datos de entrada $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ con $\mathbf{x}_i \in \mathbb{R}^n$ y sus clases correspondientes $\{y_1, \dots, y_N\}$ con $y_i \in \{1, \dots, k\}$.

2.1.2. Problema de regresión

Este problema es similar al de clasificación, pero la función que aprende el algoritmo es de la forma $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$. Por lo tanto ahora el programa debe predecir un valor

numérico (o varios si $m > 1$) para una entrada concreta. Al igual que ocurría en el problema de clasificación se disponen de una serie de datos de entrada y el resultado que se espera del programa para dichas entradas, es decir $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ con $\mathbf{x}_i \in \mathbb{R}^n$ y $\{\mathbf{y}_1, \dots, \mathbf{y}_N\}$ con $\mathbf{y}_i \in \mathbb{R}^m$.

2.1.3. Optimización

Ya se ha hablado de algunos problemas de AA. En ellos se quiere mejorar el rendimiento de una función f para una tarea. La forma en la que se mide el rendimiento es mediante otra función denominada **función de error, función de pérdida o función de coste** (Goodfellow y cols., 2016). Esta función mide el error de la aproximación de la salida de f para una entrada $\mathbf{x}$. Por lo tanto se busca minimizar dicha función.

Por ejemplo, una función de coste habitual es el error cuadrático medio:

$$ECM = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Donde $\hat{y}_i$ es la predicción de nuestro modelo para un dato x_i y y_i es el valor correcto de salida para esa entrada.

Para la minimización de la función de coste, se suelen optimizar los parámetros del modelo utilizando el método del **gradiente descendente**. Este método iterativo se basa en que, para una función multivariable dos veces diferenciable, el gradiente de dicha función en ese punto apunta en la dirección contraria de mayor ascenso. Por lo tanto tomando pasos en la dirección contraria al gradiente, debería disminuir la función de coste y por lo tanto dar un mejor rendimiento.

Se recuerda que el gradiente de una función $E : \mathbb{R}^n \rightarrow \mathbb{R}$ en un punto no es más que el vector compuesto de las derivadas parciales respecto a cada variable en dicho punto:

$$\nabla E(\mathbf{w}) = \left[\frac{\partial E}{\partial x_1}(\mathbf{w}), \dots, \frac{\partial E}{\partial x_n}(\mathbf{w}) \right]^\top$$

Usualmente, un método utilizado para resolver el problema de AA hace que las

CAPÍTULO 2. FUNDAMENTOS TEÓRICOS

funciones que se pueden representar en la solución estén parametrizadas por un vector de **pesos** $\mathbf{w}$. Por ejemplo, en un problema de regresión con función objetivo $f : \mathbb{R}^n \rightarrow \mathbb{R}$ que se plantea resolver mediante regresión lineal se tiene que la función que se aprende toma la forma:

$$f_{\mathbf{w}}(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} \quad , \mathbf{x} \in \mathbb{R}^n, \mathbf{w} \in \mathbb{R}^n$$

Donde el vector $\mathbf{w}$ son los parámetros que se pueden cambiar a la función para mejorar su rendimiento. Otros ejemplos más complejos como son el caso de redes neuronales también se pueden ver como funciones parametrizadas.

La función de coste dependerá de dichos parámetros. Luego el gradiente descendente cambiará el valor de los parámetros en cada paso buscando minimizar la función de coste. Estos cambiarán según la siguiente regla:

$$\mathbf{w}_n = \mathbf{w} - \eta \nabla E(\mathbf{w})$$

Donde $\mathbf{w}_n \in \mathbb{R}^l$ son los nuevos parámetros, $\mathbf{w} \in \mathbb{R}^l$ son los parámetros del paso actual, E es el función de coste, ∇E representa el gradiente de E y η es un hiperparámetro (parámetro del algoritmo) en $\mathbb{R}$ llamado **learning rate**(lr).

El lr determina el tamaño de los pasos tomados por el algoritmo en cada iteración. Un valor del lr alto puede hacer que el algoritmo converja más rápido pero también puede hacer que el algoritmo no llegue a converger o se salte soluciones. Por otro lado un valor bajo del lr hace que el algoritmo converja demasiado lento a un mínimo de la función. En la práctica se suelen utilizar métodos que hacen que el lr varíe a lo largo del entrenamiento, normalmente de mayor a menor.

El algoritmo del gradiente descendente inicia los pesos $\mathbf{w}$ a un valor aleatorio y empieza a iterar con la regla del descenso buscando reducir el error en cada paso durante un número de **épocas** (cada época itera sobre todos los datos de entrenamiento). En caso de converger, el algoritmo se detiene en un mínimo local del error de pérdida. Se suele buscar que la función de pérdida sea una función convexa para asegurar además que este mínimo sea global.

El cálculo del gradiente del error conlleva utilizar todos los datos de entrenamiento lo que en la práctica resulta muy costoso. Por ello se suele utilizar el **descenso de gradiente estocástico** (SGD), que en cada paso calcula una estimación del gradiente real a partir de un subconjunto aleatorio de los datos de entrenamiento denominado **mini-batch**. Destacar que los datos de entrenamiento no se deben repetir entre *minibatches*

hasta que se hayan utilizado todos los de entrenamiento entre cada repetición.

2.1.4. Sobreentrenamiento

Cuando se optimiza un modelo de IA, puede ocurrir que el modelo se ajuste muy bien para los datos de entrada con los que se ha entrenado, pero tenga mal rendimiento para datos que no se hayan visto anteriormente y por lo tanto no generaliza bien lo aprendido de los datos de entrenamiento al problema. Cuando esto ocurre, se dice que el modelo se ha **sobreentrenado** o **sobreajustado**. Una forma de identificar el sobreajuste es reservando un porcentaje de datos con los que no se va a entrenar el modelo y comparar el error del modelo a lo largo del entrenamiento de los datos de entrenamiento con los que no se han guardado. El sobreentrenamiento se puede observar cuando el error en los datos con los que no se entrena empieza a aumentar a medida que se sigue entrenando el modelo como se puede ver en la Figura 2.1.




Figura 2.1: Esta figura muestra el error en entrenamiento en azul y el error en los datos con los que no se entrena el modelo en rojo a lo largo del entrenamiento. Se puede ver como a partir de la línea verde el modelo sigue aprendiendo de los datos de entrada pero empeora el poder de generalización con los datos con los que no entrena.

2.2. Deep Learning

Deep learning(DL) o **aprendizaje profundo**, (AP) (C. M. Bishop y Bishop, 2023; Goodfellow y cols., 2016; LeCun, Bengio, y Hinton, 2015; Prince, 2023; Schmidhuber, 2015) es un subcampo del AA determinado por los métodos con los que aprende y el tipo de datos con los que trata. Los algoritmos de AP pueden tratar datos poco estructurados como pueden ser imágenes o textos. Este tipo de algoritmos automatizan la extracción de características, es decir, determinan qué información de los datos es relevante para la resolución del problema. Esto elimina parte de la intervención humana necesaria a la hora de crear el algoritmo.

El AP en los últimos años ha supuesto un avance significativo en muchos campos en los que apenas se avanzaba con otras técnicas de IA como el reconocimiento del habla o el procesamiento de lenguaje natural.

2.2.1. Redes neuronales artificiales

Una **red neuronal artificial** (RNA) (C. Bishop, 1995; Haykin, 1998; Montavon, Orr, y Müller, 2012) es un modelo de AA que consiste en una red conectada de **nodos** o **neuronas**. Cada neurona recibe una serie de números reales (entradas) de las neuronas conectadas a esta, realiza una operación con dichos números que resulta en una salida y la manda a los nodos conectados a esta.

La operación que realiza una neurona con $n \in \mathbb{N}$ entradas es la siguiente:

$$y = \sigma\left(\sum_{i=1}^n w_i x_i + w_0\right) \quad , w_i, x_i \in \mathbb{R} \quad (2.1)$$

Donde x_i son las entradas de la neurona, w_i son los **pesos** de la neurona, en particular a w_0 se le denomina *bias*, y σ es una función de los números reales a los números reales y se le denomina **función de activación** (Sharma, Sharma, y Athaiya, 2020). Al conjunto de los pesos de todas las neuronas de una red se les denomina, naturalmente, **pesos de la red**. A través de la modificación de dichos pesos es como se entrenará a una red para realizar una tarea concreta.

Existen dos tipos de RNA según el flujo de la información dentro de la red. Nos centramos en el caso en el que este flujo es una única dirección, en cuyo caso se tiene

una **red neuronal hacia delante** (*feedforward neural network* o *multilayer perceptron*, MLP).

Las MLP son el modelo fundamental del AP. Estas están compuestas por distintas **capas**, cada una compuesta de varias neuronas en paralelo. La primera capa es la **capa de entrada** que recibe la entrada a la red y la propaga a la siguiente capa. Luego puede haber una o más **capas ocultas**, donde cada una de estas están compuestas de neuronas que reciben las señales de la capas anterior y propagan su salida a las neuronas de la siguiente capa. Por último está la **capa de salida** que está compuesta por uno o varias neuronas cuya salida se considera la salida de la red. El número de capas ocultas determina la **profundidad** de la red. Se puede ver un ejemplo de un modelo de este tipo en la figura 2.2.




Figura 2.2: Ejemplo de RNA con una única capa oculta y con dos salidas. Imagen extraída de (Haykin, 1998).

Si se considera ahora la función f que implementa una red MLP, se tiene que esta depende de los pesos de la red. Una vez se tengan unos datos con los que entrenar la red y una función de coste que evalúe el rendimiento de la red, se puede aplicar el gradiente descendente estocástico para entrenar la red modificando los pesos de la misma. Sin embargo, el cálculo del gradiente de la función de error en una red puede resultar muy costoso, especialmente para el cálculo de las derivadas parciales del error respecto de los pesos de las neuronas en las capas más cercanas a la salida. Es por esto que se suele utilizar un algoritmo, denominado **backpropagation**, para el cálculo del gradiente.

CAPÍTULO 2. FUNDAMENTOS TEÓRICOS

Este algoritmo está basado en la aplicación de la regla de la cadena que dicta que si se tiene una función f que depende de otra función g que a su vez depende de otra función h , entonces se cumple que:

$$\frac{\partial f}{\partial z} = \frac{\partial f}{\partial g} \frac{\partial g}{\partial z}$$

De esta forma se puede calcular la parcial de la función de coste respecto a los pesos de una capa utilizando las parciales respecto de los pesos de la siguiente. Luego aplicando esto desde el final al principio de la red, se consigue agilizar el cálculo del gradiente de la función de coste.

Funciones de activación

Como se comenta en la ecuación (2.1), la salida de una neurona es una suma ponderada de las entradas más un sesgo, a las que se le aplica una función de activación. La inclusión de este tipo de funciones es para evitar que la red sea lineal. Si la ecuación (2.1) fuese idéntica sin aplicar la función de activación entonces la salida de la red sería una función lineal respecto de la entrada, esto es, un polinomio de primer grado. Esto haría que la red no pudiera implementar funciones complejas lo que es necesario para aprender patrones más complejos presentes en los datos. Es por esto que normalmente las funciones de activación deben ser funciones no lineales. Destacar que la función de activación debe ser derivable para poder calcular el gradiente de la función de coste con el algoritmo *backpropagation* cuando se entrene la red.

Existen varias funciones de activación que se pueden utilizar, sin embargo son especialmente interesantes la función de activación **ReLU** (*rectifier linear unit*) definida como $f(x) = \max\{0, x\}$ y la **sigmoidal** definida como $f(x) = \frac{1}{1+e^{-x}}$. Se pueden ver sus gráficas en la figura 2.3 y la figura 2.4, respectivamente.

La función de activación ReLU es la que se suele usar en las neuronas de las capas ocultas pues contrarresta el **problema de desvanecimiento del gradiente**. Un problema que afecta al entrenamiento de las redes neuronales que causa que cuando se calcula el gradiente del error para actualizar los pesos este tome valores muy pequeños haciendo que los pesos de la red cambien muy lentamente. Esto dificulta, o incluso impide, el entrenamiento de la red. Además esta función de activación es la más usada normalmente y tiene mejor rendimiento en la mayoría de los casos.

La función de activación sigmoidal se suele utilizar en la capa de salida en los

problemas de clasificación binarios.




Figura 2.3: Función de activación ReLU.




Figura 2.4: Función de activación sigmoide.

Batch normalization

Batch normalization (Ioffe y Szegedy, 2015) es un método consistente en normalizar los datos de entrada de cada capa. De esta manera se consigue hacer independiente la distribución de los datos de entrada de cada capa de la red, de los parámetros aprendidos por la red. Está probado que este método hace que el entrenamiento de la red sea más estable y más rápido. Además también se sabe que tiene un efecto regularizador en la red, lo que disminuye la probabilidad de que la red sobreentrene.

Dropout

Dropout (Hinton, Srivastava, Krizhevsky, Sutskever, y Salakhutdinov, 2012) se refiere a la técnica utilizada en redes neuronales consistente en ignorar algunas neuronas de forma aleatoria durante el periodo de entrenamiento. Usualmente se le da a

CAPÍTULO 2. FUNDAMENTOS TEÓRICOS

cada neurona una probabilidad p de ser ignorado, y en cada paso del algoritmo de entrenamiento se desconecta cada neurona de la red con dicha probabilidad. De esta forma se busca que ninguna neurona sea muy dependiente de la salida de otra neurona específica. Esta técnica regulariza la red lo que hace que la red sea menos propensa a sobreentrenar.

2.2.2. Redes neuronales convolucionales

Las **redes neuronales convolucionales** (*Convolutional neural networks, CNN*) (Li, Liu, Yang, Peng, y Zhou, 2022) son un tipo de red neuronal feedforward diseñadas para procesar datos en forma de múltiples arrays. En nuestro caso nos centraremos en el caso en el que la entrada son imágenes, que son arrays en 2 dimensiones (matrices) que contienen tres **canales**, uno por cada color primario (RGB). La estructura de las CNNs es una capa de entrada, seguida de varias capas ocultas y una capa de salida. Las capas ocultas suelen estar compuestas por una o varias **capas convolucionales** seguidas de una **capa de pooling**, esto repetido varias veces. Además al final de la red se suelen colocar una o varias **capas totalmente conectadas** hasta la capa de salida.

Capas convolucionales

Una **convolución** es un operador matemático que recibe dos funciones $f, g : \mathbb{R} \rightarrow \mathbb{R}$ y la transforma en otra función $f * g$ definida como sigue:

$$(f * g)(t) = \int_{-\infty}^{\infty} f(x)g(t - x)dx$$

Basado en este operador, existe la **convolución discreta** en 2 dimensiones, que se define como sigue:

$$(f * g)[i, j] = \sum_{m=-\infty}^{\infty} \sum_{n=-\infty}^{\infty} f(m, n)g(i - m, j - n)$$

Este operador no es más que la adaptación de la convolución al caso en el que f y g sean funciones discretas, es decir, definidas sobre los números enteros, $\mathbb{Z}$. Este es el operador que aplican las capas convolucionales a sus entradas. En el caso de las convoluciones aplicadas en una CNN f se corresponde con la entrada de la capa

convolucional y g con el **núcleo**, **kernel** o **filtro** de la convolución. El *kernel* no es más que una matriz de dimensiones $n \times m$ de valores reales. Véase la Figura 2.5 para ver un ejemplo de una convolución.




Figura 2.5: En esta imagen se puede ver un ejemplo de una convolución aplicada a una entrada de dimensiones 3×4 por un kernel de dimensiones 2×2 . Se puede ver que la salida tiene tamaño 2×3 . Notablemente se puede ver que al contrario que en la definición de la operación de convolución dada, aquí no se le da la vuelta al kernel, como suele ocurrir en la práctica. Imagen extraída de (Goodfellow y cols., 2016).

Usualmente, la entrada de las capas convolucionales tiene más de un canal (por ejemplo la capa inicial suele tener 3 canales, uno por cada color primario), en tal caso, el *kernel* tiene tantos canales como la entrada y aplica cada uno a su canal correspondiente, sumando las salidas. Para un ejemplo ver la Figura 2.6. A la salida de una convolución se le llama **mapa de características**.

Por lo visto hasta ahora, el filtro se aplica posición a posición de izquierda a derecha

CAPÍTULO 2. FUNDAMENTOS TEÓRICOS

y de arriba hacia abajo. Se denomina **stride** al parámetro que determina cada cuantas posiciones se aplica el filtro. Por ejemplo un stride de 1 aplica el filtro de forma normal. Otro parámetro que se utiliza es el **padding** que indica si se debe expandir la imagen por los bordes y con qué valores expandirla en caso de hacerlo. Por ejemplo, en la figura 2.5 no se utiliza *padding* y por lo tanto la salida tiene una fila y una columna menos.




Figura 2.6: Aquí se puede ver un ejemplo de una convolución aplicada a una entrada con 3 canales, uno por cada color primario. Se ve cómo el kernel ahora tiene 3 canales también. Imagen extraída de <https://saturncloud.io/blog/a-comprehensive-guide-to-convolutional-neural-networks-the-eli5-way/>.

Ahora que ya está claro qué es una convolución, ya se puede definir una capa convolucional como una capa que aplica $n \in \mathbb{N}$ convoluciones a una entrada. Al número de convoluciones se le denomina **profundidad** y determina el número de canales que tendrá la salida de la capa. Las dimensiones espaciales de la salida dependerán de las dimensiones espaciales de la entrada y a las decisiones de *padding* y *stride* que se hagan. Además se aplica una función de activación, posición a posición, a la salida de la capa. Esta función habitualmente es la ReLU por las razones que ya se dieron en la subsección de funciones de activación.

El objetivo de las capas convolucionales es la detección de características locales de

la entrada de la capa anterior ya que cada convolución aplica la misma operación localmente a lo largo de toda la entrada. Además, este tipo de capas tienen un número reducido de parámetros a aprender por la red ya que sólo hace falta aprender los pesos de los filtros.

Capas de pooling

Las capas de *pooling* se encargan de reducir las dimensiones espaciales de la entrada manteniendo el número de canales. Esto es, disminuyen el número de filas y columnas. Para ello dividen cada mapa de características en ventanas disjuntas que cubren todas las filas y columnas, y “resumen” todos los valores en una ventana a uno sólo. Esto disminuye el coste computacional de la red. Este tipo de capas también busca juntar valores que son similares en uno sólo.

Los dos tipos típicos de *pooling* son el **max pooling** que toma el máximo de los valores de la ventana y el **average pooling** que toma la media aritmética de los valores de la ventana. Se cree que *max pooling* tiene mejor rendimiento y, de hecho, en la parte matemática de este TFM se pueden ver argumentos de por qué podría ser cierto. En la Figura 2.7 se puede ver un ejemplo de ambos tipos de *pooling*.




Figura 2.7: En la figura se ve cómo se aplica *max pooling* y *average pooling* a una entrada. Como las ventanas tienen tamaño 2×2 se dice que se aplica *pooling* 2×2 . Imagen extraída de <https://saturncloud.io/blog/a-comprehensive-guide-to-convolutional-neural-networks-the-eli5-way/>.

Capas totalmente conectadas

Este tipo de capas no son más que una capa típica de MLP que conecta todos los valores de las neuronas de la capa anterior con todas las neuronas de esta capa. Se colocan después de todas las capas convolucionales y de *pooling*. Por ejemplo, si se quisiera resolver un problema de clasificación de imágenes en cinco clases, se tendría una última capa totalmente conectada con cinco neuronas.

2.3. XAI

Los modelos de AA se pueden dividir en dos tipos: los **modelos de caja negra** (*black-box models*) y **modelos de caja blanca** (*white-box models*) (Ali y cols., 2023; Vilone y Longo, 2021).

Los modelos de caja blanca producen resultados que pueden ser interpretados por los usuarios o expertos que utilizan el modelo, normalmente mirando sus parámetros. Los modelos primitivos de AA, como la regresión lineal, regresión logística o árboles de decisión, suelen ser de este tipo.

Por otro lado los modelos de caja negra son modelos difíciles de interpretar y explicar debido a que tienen estructuras complejas, con una gran cantidad de parámetros y comportamiento no lineal. Los modelos más importantes pertenecientes a esta clase son las RNAs.

Algunos trabajos incluyen una categoría conocida como **modelos de caja gris** (*gray-box models*), los cuales son modelos que se pueden interpretar, al menos parcialmente, si se diseñan adecuadamente.

La **Inteligencia Artificial eXplicable** (*eXplainable Artificial Intelligence, XAI*) (Longo y cols., 2024; Ali y cols., 2023; Vilone y Longo, 2021; Barredo Arrieta y cols., 2020) es un campo de estudio que pretende desarrollar métodos para construir modelos de AA que aumenten la interpretabilidad de estos sin que esto afecte demasiado a su rendimiento. Para existen dos enfoques principales: contruir modelos de caja blanca o gris con rendimientos altos y dotar a los modelos de caja negra de un mayor nivel de interpretabilidad.

Por un lado, construir modelos de caja blanca o gris con rendimientos altos implica desarrollar algoritmos basados en técnicas transparentes, como árboles de decisión, regresiones lineales o modelos basados en reglas, que logren resultados competitivos.

Estos modelos permiten a los usuarios entender con facilidad los factores que influyen en las predicciones.

Por otro lado, dotar a los modelos de caja negra de un mayor nivel de interpretabilidad busca aprovechar la potencia predictiva de algoritmos complejos, como RNAs o CNNs, con técnicas que faciliten su entendimiento. En este enfoque se encuentran herramientas como métodos de atribución de características, visualizaciones locales de importancia o aproximaciones mediante modelos simplificados.

En XAI, la **Interpretabilidad** se refiere a la capacidad de comprender cómo los modelos de IA toman sus decisiones. Por otro lado, la **explicabilidad** se refiere a la capacidad de hacer inferencias y describir el funcionamiento interno de un sistema de IA en términos humanos. Estos dos son los dos principales criterios a la hora de evaluar métodos de XAI, además de ellos existen otros como **transparencia**, **justicia** (*fairness*) y **robustez**.

En general, el objetivo de la explicabilidad es hacer algún aspecto del modelo entendible para el usuario. Si lo que se intenta hacer explicable es una salida del modelo para una instancia concreta, se habla de **explicabilidad local**. Si esa explicación además es capaz de explicar el comportamiento completo se habla de **explicabilidad global**.

Una distinción en los métodos de XAI es si el método es *ante-hoc* o *post-hoc*. Los métodos *ante-hoc* son aquellos que entrenan un modelo con el objetivo de la explicabilidad impuesto de antemano. Un ejemplo de ello son los árboles de decisión, ya que siguiendo los nodos de sus ramas se puede extraer el razonamiento intrínseco del modelo. Por otro lado los *post-hoc* pretenden explicar un modelo de caja negra después de haber sido entrenado. Un ejemplo son las redes neuronales, las cuales no están pensadas para extraer un razonamiento humano de manera directa.

A su vez, los métodos *post-hoc* se dividen en métodos **agnósticos al modelo** si funcionan para cualquier modelo, y métodos **específicos al modelo** si sólo funcionan para un tipo (o clase) de modelos. Los métodos **agnósticos al modelo** son aquellos que pueden aplicarse a cualquier modelo, independientemente de su arquitectura. Un ejemplo de ello son LIME o SHAP, los cuales estiman la contribución de cada característica a la predicción sin necesidad de conocer la estructura interna del modelo. Por otro lado, los métodos **específicos al modelo** aprovechan particularidades de un tipo de modelo concreto para extraer las explicaciones. Por ejemplo, en las redes neuronales convolucionales se pueden usar mapas de activación para visualizar qué regiones de una imagen influyen más en la predicción.

2.3.1. Explicaciones lineales locales y LIME

Las **Explicaciones lineales locales** (*Linear Local Explanation, LLE*) (Sevillano-García y cols., 2023a; Ribeiro, Singh, y Guestrin, 2016) son una clase de explicaciones para modelos de caja negra.

Sea $X \subset \mathbb{R}^F$ el *dataset* de entrada, siendo F el número de características por ejemplo, y sea $f : \mathbb{R}^F \rightarrow \mathbb{R}^C$ la función que implementa un modelo de caja negra, donde C es el número de clases de un problema de clasificación al que se aplica. Sea $x \in X$ una entrada a ser explicada. Un explicador LLE de caja blanca es una función $g : \mathbb{R}^F \rightarrow \mathbb{R}^C$ definida como:

$$g(x) = Ax + B, \quad A \in \mathcal{M}_{F,C}, B \in \mathbb{R}^C$$

Donde $\mathcal{M}_{F,C}$ es el conjunto de todas las matrices con F filas y C columnas. Es decir, g no es más que una función lineal que lleva una entrada del modelo al espacio de salida del modelo. Este modelo se puede interpretar pues intuitivamente para cada peso $a_{i,j}$ de A denota la importancia que tiene la característica de entrada i para la predicción de la salida j . Por otro lado cada valor b_j del vector B está conectado con la importancia en general de la salida j .

Para obtener la función g anterior los métodos LLE utilizan regresión lineal sobre una vecindad del ejemplo x . El error que minimizan es el siguiente:

$$\mathcal{L}(f, g, \pi_x) = \sum_{z \in N(x)} \pi_x(z) (f(z) - g(z))^2$$

Nótese que esto no es más que el error cuadrático medio ponderando cada vecino por una función π_x que mide la proximidad a x para cada vecino generado z , que dependerá del LLE utilizado. Aquí $N(x)$ representa el vecindario de x para el número de vecinos generados es un parámetro del LLE.

El método de **explicaciones locales interpretables agnósticas al modelo** (*Local Interpretable Model-agnostic Explanations, LIME*) (Sevillano-García y cols., 2023a; Ribeiro y cols., 2016) es una técnica LLE considerada como estado del arte. En LIME se realiza una regresión de cresta (*Ridge regresion*) para obtener g , definiendo la $\pi_x(z)$ como sigue:

$$\pi_x(z) = e^{\frac{-d(x,y)^2}{\sigma^2}}$$

dónde $d(\cdot, \cdot)$ es la distancia euclídea (en el caso de imágenes) y σ es un factor de regularización.

Para la generación de vecinos en $N(x)$ se muestrea un valor v' de la distribución exponencial $Exp(\lambda)$ con $\lambda = \frac{1}{\sigma}$. Después se toma $v = \min\{\lfloor v' \rfloor, F\}$. El valor v determina cuantas características de x se van a ocultar. Estas se escogen de forma aleatoria (uniformemente).

La elección de lo que es una característica depende del tipo de dato con el que se trate. En el caso de este TFM se trata con imágenes. Para las imágenes se puede tratar cada pixel individualmente como una característica. Sin embargo esto hace que haya muchas características lo que hace que generar este tipo de explicaciones sea caro. Además desde un punto de vista humano un pixel individual no suele tener un significado específico en una imagen, es más natural que un conjunto de pixeles tengan un significado. Por ello consideramos una división de la imagen en cuadrados del mismo tamaño y cada uno de ellos conlleva una característica.

2.3.2. Métricas ReVEL

El framework **Evaluación robusta vectorizada de explicaciones-lineales-locales** (*Robust Evaluation VEcторized Loca-linear-explanation, REVEL*) (Sevillano-García y cols., 2023a) ofrece un análisis robusto y consistente de explicaciones LLEs generadas para modelos de caja negra. En este se presentan cinco métricas que miden distintos aspectos cualitativos de la explicación.

Antes de introducir estas métricas introduzco algunas matrices antes. Nos situamos en un problema de clasificación en el que hemos entrenado un modelo de caja negra, sea g una explicación generada por un LLE, tal que $g : F \rightarrow Y_l$ dónde Y_l es el espacio *logit*. Este espacio no es más que la salida del modelo de caja negra antes de aplicar la función *softmax* que transforma la salida del modelo a probabilidades de cada clase. Recordar que $g(x) = Ax + B$.

Se define la **matriz de importancia con signo**, A^l como la matriz derivada sobre el espacio *logit*. Como es evidente al ser lineal $A^l = A$. Por otro lado, para la obtención del vector de probabilidades p se necesita aplicar la función *softmax* a $g(x)$ luego $p = \text{softmax}(g(x)) = \text{softmax}(Ax + B)$. Se define la matriz $A^p = D(\text{softmax}(g(x)))(x)$

CAPÍTULO 2. FUNDAMENTOS TEÓRICOS

siendo $D(\cdot)$ el operador derivada. La función *softmax* es la función que para clase c se define como:

$$\text{softmax}(y_1, y_2, \dots, y_C)_c = \frac{e^{y_c}}{\sum_{i=1}^C e^{y_i}}$$

La forma de interpretar estas dos matrices es teniendo en cuenta que el elemento en la fila i y columna j de cada matriz representa la importancia de la característica i sobre la clase j sobre los espacios *logit* y *probabilidad*. Por un lado A^l da información sobre como afecta, positiva o negativamente dependiendo del signo, cada característica a los distintos *logits* de las clases. Por otro lado, A^p proporciona información sobre las clases en las que el ejemplo es más probable de ser clasificado.

Como ambas matrices presentan información relevante se define la **matriz de importancia** como la matriz que combina la información de A^l y A^p como sigue:

$$A_{i,j} = \text{sign}(A_{i,j}^l) \sqrt{|A_{i,j}^l| \cdot |A_{i,j}^p|}$$

A partir de esta matriz se define la **matriz de importancia normalizada** $A_r = \frac{A}{\max_{A_{i,j}} \{|A_{i,j}|\}}$ que lleva los valores de A al rango $[-1, 1]$ manteniendo su signo. Finalmente se define la **matriz de importancia absoluta** como la matriz $|A|$ que simplemente es la matriz A_r con todos sus elementos en positivo.

Leyendo tu artículo no me queda claro si la matriz de importancia absoluta es $|A_z|$ o $|A|$

Ya estamos en condiciones de introducir las cinco métricas introducidas en REVEL. De aquí en adelante $g(x)$ se toma en el espacio de probabilidades, no en el de *logit*.

Local concordance

Se define como:

$$\text{Local_Concordance}(g) = 1 - \frac{\|f(x) - g(x)\|}{C'}$$

Dónde $\|\cdot\|$ es una norma arbitraria (por ejemplo la norma euclídiana $\|\cdot\|_2$) y C' es

la distancia máxima posible entre dos vectores de probabilidad (por ejemplo en el caso de $\|\cdot\|_2$ se cumple que $C' = \sqrt{2}$).

Notemos que esta métrica está definida en el intervalo $[0, 1]$ dónde el valor máximo se alcanza cuando $f(x) = g(x)$ y la mínima ocurre cuando ambas funciones clasifican x en clases distintas con probabilidad 1.

Esta métrica mide cómo de similar es la explicación al ejemplo original de la caja negra. Es importante que esté cercana a 1 ya que en otro caso la explicación propuesta no se corresponde con el ejemplo escogido.

Local fidelity

Se define como:

$$Local_Fidelity(g) = \frac{1}{|N(x)|} \sum_{z \in N(x)} 1 - \frac{\|f(z) - g(z)\|}{C'}$$

Dónde $|N(x)|$ es el número de vecinos generados para la explicación.

Esta métrica se puede ver como la media de la métrica anterior sobre los vecinos de x , por lo tanto también está definida en el intervalo $[0, 1]$. Esta métrica mide cómo de cercan están las probabilidades calculadas por el modelo de caja blanca de las que calcula el modelo de caja negra. Luego mide la similitud entre la explicación y el modelo f en la vecindad de x . Al igual que pasaba con la *local concordance*, debe ser cercano a 1 para obtener buenas explicaciones.

Prescriptivity

Se define como:

$$Prescriptivity(g) = 1 - \frac{\|f(x+h) - g(x+h)\|}{C'}$$

Dónde h es una perturbación sobre x que quita la presencia de las características más importantes (de forma positiva) de la clase asignada por g al ejemplo x . De esta forma, para encontrar h se van quitando dichas características hasta que se cumpla que $\text{argmax}(g(x)) \neq \text{argmax}(g(x+h))$.

CAPÍTULO 2. FUNDAMENTOS TEÓRICOS

Notemos que esta métrica también está contenida en $[0, 1]$ y obtiene el valor 1 cuando $f(x + h) = g(x + h)$ y obtiene el valor 0 cuando ambas funciones clasifican $x + h$ en clases distintas con probabilidad 1.

Esta métrica pretende estudiar si la explicación g es capaz de predecir correctamente los cambios necesarios en el ejemplo x para cambiar la clase original. Para ello busca un valor lo suficientemente alejado del ejemplo para que la explicación cambie la clase predicha y mida cómo cambia la predicción respecto del modelo de caja negra. Al contrario que las dos métricas anteriores un valor cercano a 1, aunque buscado, no es necesario para obtener buenas explicaciones.

Conciseness

Se define como:

Aquí he adaptado la fórmula de <https://arxiv.org/abs/2211.06154> con la información de la documentación de tu código en github para que quede más claro (a mí me queda más claro).

$$\text{Conciseness}(g) = \frac{1}{f' - 1} \sum_{i=1}^{f'} 1 - I_i$$

Dónde f' es el número de filas de la matriz de importancia absoluta (equivalentemente, número de clases), sea v_i el vector fila i de la matriz $|A|$ entonces:

$$I_i = \frac{\|v_i\|}{\max_{1 \leq j \leq f'} \{\|v_j\|\}}$$

Observemos que v_i es un vector en que cada elemento j representa la importancia de la característica i para la clase j luego se puede interpretar que I_i es la importancia de dicha característica (normalizada a $[0, 1]$). Si analizamos la expresión de la métrica tenemos que esta está comprendida entre $[0, 1]$ y alcanza 1 si una métrica tiene importancia 1 y el resto tiene importancia 0. Si todas las características tuvieran la misma importancia, por estar I normalizada serían todas 1 y se obtendría el menor valor posible en 0.

Esta métrica busca medir la brevedad de la explicación, es decir, cuantas menos características sean relevantes para la explicación, más concisa se considera la explicación.

Luego mide la habilidad de la explicación de concentrarse en las características importantes. Al contrario que las métricas anteriores, dependiendo de la tarea se podría querer más o menos *conciseness* ya que valores demasiados bajos podrían indicar que el modelo se centra en cosas irrelevantes (por ejemplo en imágenes que se centre en pocos píxeles podría ser malo).

Robustness over explanations

Se define como:

$$Robustness(G) = \mathbb{E}[similarity(g, g')]$$

Dónde G representa el conjunto de todas las explicaciones que podría generar el LLE, $\mathbb{E}$ es la esperanza y *similarity* es una función que mide cuanto difieren dos explicaciones distintas y se define como:

$$similarity(g, g') = \left(\frac{A_r \cdot A'_r}{\|A_r\| \|A'_r\|} \right) \left(1 - \frac{|\|A_r\| - \|A'_r\||}{\max\{\|A_r\|, \|A'_r\|\}} \right)$$

Observemos que la componente de la derecha mide cómo de similares son las magnitudes de las matrices de importancia absoluta normalizadas de las explicaciones mientras que el valor de la izquierda se corresponde con la similaridad coseno entre A_r y A'_r (matrices correspondientes con g y g' correspondientemente), esta mide como distan las direcciones de las explicaciones. El producto de matrices de esta función es el elemento a elemento. El mejor caso, cuando ambas explicaciones son iguales, se tiene que la similaridad es 1 y el peor caso ocurre son “perpendiculares” y la similaridad es 0.

En la práctica, para aproximar la *Robustness* se hace la media de la similaridad generando muchas otra explicaciones g' para x . Esto únicamente se puede hacer para LLEs que no son deterministas, pues en otro caso siempre se tendría la misma explicación y obtendrían siempre 1. Por ejemplo con LIME sí se puede calcular esta métrica pues tiene no determinismo en la generación de la vecindad.

Esta no es una métrica sobre la explicación en específico sino sobre el método que las genera. Cuanta más cercana a 1 menos varían las explicaciones generadas por el método estudiado. Esta métrica al contrario que todas las anteriores puede obtener valores negativos, lo que indicaría explicaciones que se “contradicen”.

2.3.3. Regularización X-Shield

La **regularización** (Sevillano-García y cols., 2023b; Moradi, Berangi, y Minaei, 2020) es la modificación de la arquitectura del modelo, del proceso de entrenamiento o inferencia para imponer algún criterio sobre este. Por ejemplo, dropout, que ya se vió previamente, es una regularización.

En particular nos interesan las regularizaciones que implican añadir a la función de coste un nuevo término que indica el criterio que queremos minimizar en el modelo. Algunos ejemplos típicos son la regularización L1 o L2. En general se tiene que una regularización de este tipo se expresa como:

$$\text{coste_regularizado}(\Theta, X, Y) = \text{coste}(f_{\Theta}(X), Y) + \text{regularizacion}(X, \Theta)$$

Dónde se tiene que Θ son el conjunto de parámetros del modelo, X son las entradas del conjunto de datos y Y las salidas. Por lo tanto la regularización es una función que puede ser de los parámetros y de las datos de entrada.

En primer lugar presentamos la familia de regularizaciones *Transformation-Selective Hidden Input Evaluation for Learning*, **T-SHIELD** (Sevillano-García y cols., 2023b). Esta está diseñada para hacer que el modelo aprenda con menos features. Para ello se oculta parte de la entrada.

Para ello se utiliza una transformación $T : \mathbb{R}^F \rightarrow \mathbb{R}^F$ tal que $T(x)_i = x_0$ si i es una característica a esconder y $T(x)_i = x_i$ si no lo es. Es decir esta transformación cambia todas las características de una entrada x por un valor constante x_0 y deja el resto intactos.

Para una transformación T como la anterior descrita, se define la regularización T-SHIELD como sigue:

$$T - \text{SHIELD}(x, \Theta) = KL(f_{\Theta}(T(x)), f_{\Theta}(x)) + KL(f_{\Theta}(x), f_{\Theta}(T(x)))$$

Dónde $KL(\cdot, \cdot)$ denota la distancia de Kullback-Leibler, que se trata de un tipo de distancia que mide como difieren dos distribuciones distintas. Por lo tanto esta regularización no es más que la distancia de Kullback-Leibler simétrica. Según como se construya la transformación T esta regularización penalizará ciertos aspectos del modelo. En la Figura 2.8 se puede ver cómo funcionaría una regularización de esta familia de forma general.




Figura 2.8: En esta figura se puede ver cómo funciona en general la familia de regularizaciones T-SHIELD durante el entrenamiento. En gris se puede ver el flujo normal de la imagen en el modelo. En azul se encontraría la forma en la que la regularización decide qué características ocultar. Finalmente en rojo se encontraría el flujo de la imagen con las características ya ocultas y cómo se calcula la función de regularización. Imagen extraída de (Sevillano-García y cols., 2023a).

Se denomina **Random-SHIELD (R-SHIELD)** a la regularización de la familia T-SHIELD que para un parámetro $\lambda \in [0, 100]$ define la transformación T como aquella que esconde un λ % de las características de forma aleatoria (misma probabilidad para cada una).

Se denomina **XAI-SHIELD (X-SHIELD)** a otra regularización de la familia T-SHIELD. Comparte el parámetro λ de R-SHIELD pero en vez de ocultar el λ % de características aleatorias, va a ocultar las λ % menos importantes. Para ello, a cada característica le otorga la importancia $\|v_i\|$ donde v_i es la fila i de la matriz de importancia A introducida en la subsección 2.3.2, pero para el modelo que se está entrenando.

De manera más formal se describe $T_{xai}(x; \lambda)$ como la transformación:

$$T_{xai}(x_1, \dots, x_F; \lambda) = (\underbrace{x_0, x_0, \dots, x_0}_{0 \leq i \leq F: \lambda < \frac{i}{n} \cdot 100\%}, x_i, x_{i+1}, \dots, x_F)$$

Dónde se ha supuesto los atributos x_i ordenados de menor a mayor por importancia y tenemos que i es el menor valor tal que se ocultan al menos el λ % de características.

En la Figura 2.9 se puede apreciar la diferencia entre los comportamientos de los dos

CAPÍTULO 2. FUNDAMENTOS TEÓRICOS




Figura 2.9: Comparación entre el comportamiento de T en R-SHIELD y X-SHIELD. La imagen está sacada del dataset *Flowers* de clasificación de imágenes de flores. Se puede ver que R-SHIELD oculta partes de la imagen aleatorias, incluyendo partes de la flor a clasificar. Por otro lado X-SHIELD oculta partes del fondo de la imagen que intuitivamente no parecen útiles para clasificar dicha flor. Imagen extraída de (Sevillano-García y cols., 2023a).

tipos de regularización T-SHIELD vistos.

3 Estado del arte

Este Trabajo de Fin de Máster trata de abarcar el problema de construir un modelo de IA de clasificación para lesiones cancerosas en biopsias de próstata y de la mejora en explicabilidad del modelo mediante técnicas de XAI. Por lo tanto vamos a hacer una revisión del estado del arte para los cuatro siguientes puntos que son relevantes para nuestro TFM:

- Redes neuronales convolucionales para clasificación de imágenes.
- Métodos de XAI para producción de explicaciones, en particular, las LLEs.
- Métodos de XAI de regularización para mejorar las explicaciones.
- Métricas de XAI para evaluar la calidad de las explicaciones producidas para poder comparar los distintos métodos utilizados.

Modelo de clasificación de imágenes

Efficientnet (Tan y Le, 2019) es una red introducida en 2019 que se sigue considerando estado del arte en clasificación de imágenes cuando se mide eficiencia computacional, es decir, rendimiento obtenido por número de parámetros. En la Figura 3.1 se puede apreciar como es más eficiente en cómputo respecto a otros modelos de clasificación de imágenes como ResNet (He, Zhang, Ren, y Sun, 2015) o DenseNet (Huang, Liu, van der Maaten, y Weinberger, 2018) para el dataset Imagenet.

Existen otros modelos más modernos como CoCa (Yu y cols., 2022), DaViT (Ding y cols., 2022) o ConvNeXt V2 (Woo y cols., 2023), que utilizan transformadores en el caso de CoCa y DaViT, o autoencoders, en el caso de ConvNeXt V2. Estos modelos alcanzan precisiones mayores que EfficientNet. Sin embargo, aumentan demasiado el número de parámetros utilizados como para que sea una propuesta viable para nuestro trabajo.

Por ello, hemos decidido utilizar el modelo EfficientNet en este trabajo ya que ofrece un balance muy bueno entre número de parámetros y precisión. En la Tabla 3.1 se

CAPÍTULO 3. ESTADO DEL ARTE

puede apreciar las diferencias entre el modelo que utilizaremos EfficientNet-B2, y las versiones más pequeñas de los modelos mencionados. Se aprecia que EfficientNet es más eficiente en el número de parámetros.

Modelo	Arquitectura Base	Parámetros	Precisión Top-1
EfficientNet-B2	CNN	9.1M	80.1 %
DaViT-Small	CNN + Transformer	49.7M	84.2 %
ConvNeXt V2-Tiny	CNN moderna (con Masked Autoencoder)	28.6M	85.1 %
CoCa-Base	Transformer	383M	91.0 %

Tabla 3.1: Comparación de modelos en términos de precisión Top-1 en ImageNet y número de parámetros.

Métodos de XAI para producción de explicaciones

Una revisión de todos los métodos de explicabilidad *post-hoc*, que son los que se aplican a modelos de caja negra, está fuera del alcance de este trabajo. Sin embargo, resumimos algunos métodos populares (esquema en la Tabla 3.2):

- **LIME** (Ribeiro y cols., 2016): Modelo explicado con detalle en la subsección 2.3.1.
- **SHAP** (SHapley Additive exPlanation) (Lundberg y Lee, 2017): Basado en valores de Shapley de teoría de juegos. Atribuye importancia a cada variable de forma consistente; permite explicaciones locales y globales.
- **LRP** (Layer-wise Relevance Propagation) (Montavon, Binder, Lapuschkin, Samek, y Müller, 2019): Propaga hacia atrás la relevancia de la predicción a través de cada capa de la red. Muy usado en visión y señales neuronales.
- **CRP** (Concept Relevance Propagation) (Achtibat y cols., 2023): Extiende LRP incorporando información contextual o conceptual. Promete explicaciones más interpretables en términos humanos.
- **Grad-CAM** (Gradient-weighted Class Activation Mapping) (Selvaraju y cols., 2017): Técnica visual para CNNs que genera mapas de calor mostrando qué regiones de una imagen influyen en la clasificación.
- **Integrated Gradients** (Sundararajan, Taly, y Yan, 2017): Método axiomatizado de atribución que compara la entrada con una baseline. Proporciona asignaciones más estables que gradientes simples.




Figura 3.1: En esta gráfica se compara las distintas versiones de Efficientnet, Bo-7, contra otros modelos de redes convolucionales. Se puede apreciar que es la más eficiente. Imagen extraída de (Tan y Le, 2019).

Técnica	Tipo	Enfoque
LIME	Modelo-agnóstico	Local
SHAP	Modelo-agnóstico	Local y Global
LRP	Modelo-específico (DNN)	Local
CRP / Concept R.P.	Modelo-específico (DNN)	Local
Grad-CAM (+ variantes)	Modelo-específico (CNNs)	Visual
Integrated Gradients	Modelo-específico (DNN)	Local (atribución)

Tabla 3.2: En esta tabla se muestran algunas técnicas clave de XAI.

CAPÍTULO 3. ESTADO DEL ARTE

En este estudio nos hemos dejado muchos métodos como explicaciones por ejemplos (como generación de *counterfactuals* (Liu, Kailkhura, Loveland, y Han, 2019)) o las muchas extensiones de los métodos mentados (por ejemplo para LIME en (Knab, Marton, Schlegel, y Bartelt, 2025)) hay una taxonomía de estos).

Métricas para explicaciones

Dado que hay muchos tipos de explicaciones en la literatura (LLEs, mapas de atribución, reglas...) no hay manera de comparar estas directamente. Debido a esto, existen distintas métricas para medir de forma cuantitativa la calidad de las explicaciones.

En (Rosenfeld, 2021), se proponen cuatro métricas para medir la calidad de explicaciones. Sin embargo, estas son específicas para explicaciones basadas en reglas. Las métricas que proponen son:

- *D*: la diferencia en rendimiento entre el modelo a explicar y la explicación basada en reglas. Cuantifica el cambio entre el modelo de caja negra y el mejor modelo de caja blanca observado.
- *R*: El número de reglas de la explicación. Busca cuantificar lo fácil de entender que es la explicación.
- *F*: El número de características que se han utilizado para construir la explicación. Es similar a *R*; cuanto menor es mejor se considera la explicación.
- *S*: La estabilidad de la explicación. Cuantifica la habilidad de la explicación de manejar robustamente perturbaciones pequeñas. Para su cálculo se introducen pequeñas perturbaciones en los datos (sin cambiar las etiquetas), se vuelve a generar una explicación para los distintos datos perturbados y finalmente se calcula la media de la distancia de estas con la explicación para el dato original mediante medidas de similitud como *Jaccard* o *Tanimoto*.

En (Amparore, Perotti, y Bajardi, 2021) se propone el framework *LEAF*. En este, se introducen 4 métricas y 1 restricción (*conciseness*) para evaluar de forma clara las explicaciones de LLEs. Sea f la función que implementa un modelo de caja negra y g el modelo de una LLE, entonces las métricas y la restricción de *LEAF* son las siguientes:

- *Conciseness*: se interpreta como hasta qué punto el modelo es entendible por un humano. Se define como el número de pesos de la explicación (es una LLE) que

son distintos de cero en la explicación dada al usuario. Por ejemplo en LIME en un número fijado a priori.

- *Local Fidelity*: mide cómo el modelo de caja blanca g (la explicación) aproxima el comportamiento del modelo de caja negra f para un ejemplo x y su vecindad $N(x)$. Este se calcula con el $F1$ -score sobre dicha vecindad y dependerá por lo tanto de cómo se muestree ésta.
- *Local Concordance*: mide cómo g aproxima a f justo en el ejemplo x . Se mide como $\max\{0, 1 - |f(x) - g(x)|\}$.
- *Reiteration Similarity*: muchos métodos de LLEs utilizan aleatoriedad para generar sus explicaciones. Debido a esto, aplicar muchas veces un algoritmo para generar una explicación para un mismo ejemplo x puede generar explicaciones distintas cada vez. Se propone esta métrica para medir la similitud del conjunto de explicaciones generadas. Ésta se calcula como la similaridad de *Jaccard* J esperada entre dos explicaciones g y g' . Es decir, $\mathbb{E}[J(g, g')]$.
- *Prescriptivity*: Intuitivamente, esta mide qué tan útil es una explicación local para indicar los cambios mínimos necesarios en una instancia x que harían que el modelo la clasifique de otra manera. Se calcula proyectando x sobre la frontera de decisión del modelo explicativo g , y evaluando qué tan cerca está esa proyección del límite. Sea x' dicha proyección entonces; se calcula como la pérdida *hinge* normalizada de $f(x') - g(x')$.

Finalmente, en (Sevillano-García y cols., 2023a) se introducen las métricas REVEL, que ya hemos introducido en 2.3.2. Este framework propone cinco métricas al igual que LEAF. REVEL está compuesto de las mismas 5 métricas, cambiando *Reiteration Similarity* por *Robustness* que busca medir lo mismo. Sin embargo, REVEL cambia cómo se calcula cada una de las métricas introduciendo mejoras en todas ellas. Es por esto que vamos a utilizar en este trabajo estas métricas para medir la calidad de nuestras explicaciones. A continuación indico las mejoras que introduce cada métrica en REVEL respecto a la correspondiente métrica o restricción en LEAF:

- *Conciseness* (igual en LEAF): En LEAF esta se proponía como restricción para las explicaciones y no como métrica. En contraste, REVEL introduce como una métrica a evaluar para cada explicación g .
- *Local Fidelity* (igual en LEAF): El método LEAF evalúa la similitud entre una explicación g y el modelo f mediante la métrica $F1$ -score en el vecindario $N(x)$, pero el uso del $F1$ -score presenta dos limitaciones: el desbalanceo de clases en

CAPÍTULO 3. ESTADO DEL ARTE

dicho vecindario (comparten clase con el ejemplo la mayoría) y los problemas en los bordes de decisión hacen que penalice casos en los que la explicación imita correctamente la incertidumbre del modelo. Por otro lado, la métrica REVEL no tiene problema con el desbalanceo de clases en $N(x)$ ni está sesgada por la selección de un umbral.

- *Local Concordance* (igual en LEAF): La propuesta LEAF utiliza una función no diferenciable para el cálculo de esta, mientras que la de REVEL es diferenciable. Por lo tanto la propuesta de REVEL supera las inconsistencias de LEAF.
- *Robustness* (*reiteration similarity* en LEAF): En LEAF mide cuánto varían dos explicaciones generadas por el mismo método al comparar las *top-k* características seleccionadas en cada caso, esto presenta tres desventajas: depende directamente de la restricción *conciseness*, no toma en cuenta la importancia relativa de las características, penalizando por igual la selección de características relevantes e irrelevantes, y no penaliza escoger características importantes que son positivas como negativas. En cambio, la propuesta de REVEL no depende de restricciones externas y no tiene los otros problemas previamente descritos.
- *Prescriptivity* (igual en LEAF): En LEAF, esta mide qué tan cerca está un ejemplo de cambiar de clase según la proyección sobre una frontera fija, usando la función *hinge* normalizada. Sin embargo, presenta varias limitaciones: está diseñada para una sola variable de salida, depende de un valor fijo y , no garantiza cambios de clase en problemas de clasificación con más de dos clases y no asegura un aumento suave de 0 a 1. En REVEL el cálculo de esta considera todo el vector de probabilidades, no depende de fronteras fijas y está bien definida en el intervalo $[0, 1]$, con un aumento suave del peor valor posible al mejor.

Métodos de regularización XAI

Los métodos de regularización en XAI (Sevillano-García y cols., 2023b; Weber, Lapuschkin, Binder, y Samek, 2023), que añaden un término regularizador a la función de pérdida, plantean una manera sencilla para modificar el comportamiento del modelo, favoreciendo criterios de mejora de explicabilidad. Estos son por construcción agnósticos al modelo, aunque algunos requieren que éste sea diferenciable, y sencillos de implementar.

En (A. S. Ross, Hughes, y Doshi-Velez, 2017) se introduce *Right for the Right Reasons* (RRR) que busca optimizar el razonamiento del modelo. En este trabajo el conjunto de

datos X , además de estar etiquetado, debe proveer una máscara en la que se indique si cada dimensión de la entrada debe ser relevante o irrelevante para la decisión. En este trabajo las explicaciones se hacen mediante el gradiente respecto al logaritmo de la salida del modelo. Su principal inconveniente es que requiere

En (A. Ross y Doshi-Velez, 2018) se realiza un método similar al anterior, pero solucionan el problema de la anotación manual de los datos para determinar qué parte de las entradas son irrelevantes. En éste se generan perturbaciones de la entrada y se calculan sus mapas de atribución. El componente regularizador penaliza cambios significativos en las explicaciones. Este método busca que las explicaciones sean más estables y robustas.

En (Rieger, Singh, Murdoch, y Yu, 2020) se introduce *Contextual Decomposition Explanation Penalization* (CDEP). Éste utiliza la diferencia absoluta entre la explicación producida y la explicación dada por un experto. Para ello, se emplea el método *Contextual Decomposition* (CD) como técnica de atribución, que permite calcular explicaciones diferenciables durante el entrenamiento. De esta forma, se penaliza directamente en la función de pérdida cualquier discrepancia entre el razonamiento del modelo y el conocimiento previo. Sin embargo, obtener el conocimiento previo de expertos puede resultar muy costoso. Los autores proponen definir reglas automáticas que identifiquen las regiones importantes, esto sigue requiriendo un experto que defina dichas reglas.

Finalmente, en (Sevillano-García y cols., 2023b) se introduce X-SHIELD, el método del que partimos. Este método no tiene restricciones teóricas sobre la entrada, salida o tarea que realiza el modelo, salvo que el modelo sea diferenciable. La aplicación de esta regularización mejora el rendimiento en las métricas REVEL, lo que nos proporciona un método base con el que comparar nuestras propuestas. X-SHIELD también ha demostrado que es capaz de aumentar las métricas REVEL mientras que también mejora en muchos casos el rendimiento en clasificación del modelo.

4 Métodos

4.1. EfficientNet

El modelo de clasificación de imágenes que vamos a entrenar sobre nuestro conjunto de datos y sobre el que aplicaremos las distintas regularizaciones XAI se trata de **EfficientNet** (Tan y Le, 2019). EfficientNet es una familia de CNNs muy eficiente en rendimiento, obteniendo buenos resultados en *accuracy* versus número de parámetros presentes en la red (Figura 3.1). Esto hace que sea muy versátil y se adapte al poder de cómputo del que disponemos. Además la precisión final obtenida por la red, aunque es relevante, no es el objetivo central que ocupa este trabajo ya que también buscamos mejorar la interpretabilidad del modelo.

De entre la familia de estas redes hemos elegido **EfficientNet-B2** para realizar nuestros experimentos pues es el que mejor se adapta a nuestra potencia de cómputo (en la Tabla 4.1 se pueden ver los detalles).

Modelo	Parámetros (M)	FLOPs (B)
EfficientNet-Bo	5.3	0.39
EfficientNet-B1	7.8	0.7
EfficientNet-B2	9.2	1
EfficientNet-B3	12	1.8
EfficientNet-B4	19	4.2
EfficientNet-B5	30	9.9
EfficientNet-B6	43	19
EfficientNet-B7	66	37

Tabla 4.1: Modelos EfficientNet Bo–B7 con número de parámetros y FLOPs (*Floating Point Operations per second*). Datos extraídos de (Tan y Le, 2019)

En la Tabla 4.2 muestro la arquitectura de EfficientNet-B2. Los bloques **MBConv1** y **MBconv6** son los bloques *inverted bottleneck* introducidos en (Sandler, Howard, Zhu, Zhmoginov, y Chen, 2018) combinados con bloques *Squeeze-and-excitation* (SE) introducidos en (Hu, Shen, Albanie, Sun, y Wu, 2020).

CAPÍTULO 4. MÉTODOS

Estapa	Operador	Resolución	#Canales de entrada	#Capas
1	Conv3x3	224 × 224	32	1
2	MBConv1, k3x3	112 × 112	16	1
3	MBConv6, k3x3	112 × 112	24	2
4	MBConv6, k5x5	56 × 56	48	2
5	MBConv6, k3x3	28 × 28	88	3
6	MBConv6, k5x5	14 × 14	120	3
7	MBConv6, k5x5	14 × 14	208	4
8	MBConv6, k3x3	7 × 7	352	1
9	Conv1x1 + Pooling + FC	7 × 7	1408	1

Tabla 4.2: Arquitectura de EfficientNet-B2 con entrada de 224 × 224.

4.2. XSHIELD

X-SHIELD (Sevillano-García y cols., 2023b) es el método de regularización XAI con el que vamos a comparar los métodos propuestos a continuación. Además, nuestros métodos están basados en los mismos principios que este método: esconder al modelo las características menos relevantes y penalizar la diferencia entre la predicción original del modelo y la predicción sin dichas características. Todos los detalles acerca de XSHIELD están en la subsección 2.3.3.

4.3. Métodos propuestos

En las siguientes tres subsecciones voy a introducir mis propuestas de métodos de regularización desarrolladas en este trabajo.

4.3.1. FX-Shield

En **FX-SHIELD** (*Feature X-SHIELD*) proponemos una regularización que oculta la distintas características extraídas por la parte de red convolucional del modelo. La idea principal es mejorar la interpretación del modelo evaluando la importancia de sus características intermedias. Por ejemplo, en una red convolucional que analiza una imagen: primero extrae características que representan patrones (bordes, texturas, formas, conceptos), y luego usa estos para realizar la clasificación final. FX-SHIELD funciona evaluando qué pasa si las menos importantes según el modelo se ocultan. Al ver cómo cambia la predicción, podemos regularizar el modelo y ver cuáles son realmente importantes para su decisión.

4.3. MÉTODOS PROPUESTOS

Formalmente, sea $x \in \mathbb{R}^F$ un dato de entrada; luego F es el número de características de la entrada. Sea $f : \mathbb{R}^F \rightarrow \mathbb{R}^C$ la función que implementa el modelo de caja negra, siendo C el número de clases del problema. En el caso de una red convolucional se tiene que $f(x) = l(c(x))$ donde $c : \mathbb{R}^F \rightarrow \mathbb{R}^{F_c}$ es la función que implementan las capas convolucionales de la red y $l : \mathbb{R}^{F_c} \rightarrow \mathbb{R}^C$ la función que implementan las capas no convolucionales (por ejemplo una o varias capas totalmente conectadas). En las expresiones anteriores, F_c representa el número de características que extrae la red convolucional de las entradas (ver Figura 4.1). Por ejemplo, en la Tabla 4.2 podemos ver que para EfficientNet-B2 se tiene que $F_c = 1408$.




Figura 4.1: Esquema de la red completa. En este se diferencian las características extraídas por las capas convolucionales de la red de las características de la entrada.

En X-SHIELD las características de las entradas, si son imágenes, dependen de cómo se quieran definir. Hay varias posibilidades como tomar que cada píxel se corresponda con una característica, dividir la imagen de entrada en cuadrados del mismo tamaño o utilizar métodos para dividir la imagen de entrada en superpíxeles. En FX-SHIELD no hace falta tomar esta decisión porque independientemente de la imagen de entrada (incluso para distintos tamaños de ésta) siempre se va a obtener el mismo número F_c de características extraídas por los bloques convolucionales, es decir, la representación interna es consistente entre imágenes. Esto es una ventaja sobre X-SHIELD porque: elimina decisiones arbitrarias que podrían afectar al entrenamiento y hace que el método se pueda aplicar a diferentes conjuntos de datos y resoluciones de manera más sencilla.

Sean $z = c(x)$ las características intermedias. Ahora buscamos ocultar las características menos importantes de z . La importancia que se le da a las distintas características se puede definir con la matriz de importancia $\mathcal{A} = \frac{\delta f}{\delta Z}(x) = \frac{\delta l}{\delta Z}(z)$. Para cada característica $i \in \{1, 2, \dots, F_c\}$ vamos a definir la importancia de ésta como:

CAPÍTULO 4. MÉTODOS

$$I_i(z) = \frac{\|\mathcal{A}_i\|_1}{C} = \frac{1}{C} \sum_{j=1}^C |\mathcal{A}_{i,j}|$$

Por lo tanto esta es la media aritmética de la suma absoluta de la derivada de cada valor de salida sobre dicha características. Volviendo al ejemplo de la arquitectura de EfficientNet-B2 4.2 tenemos que la cabeza de la red consta de una única capa totalmente conectada, es decir en este caso se tiene que:

$$l(z) = Az + B$$

Dónde A es una matriz real de dimensión $C \times F_c$ y B es un vector de C valores. Como l es una aplicación lineal se sigue que $\mathcal{A} = A$ y la importancia no es más que la suma para cada característica de los valores de A para esta.

Sea $\lambda \in [0, 100]$ un parámetro que determina que porcentaje de las características se va a ocultar, definimos la siguiente transformación $T_{fxshield} : \mathbb{R}^{F_c} \rightarrow \mathbb{R}^{F_c}$ que enmascara el λ % de elementos menos importantes. En la práctica se escoge el menor m tal que $\lambda < \frac{m}{F_c} \cdot 100$ y se enmascaran las m características menos importantes. En X-SHIELD, como se enmascaran características de la entrada que son imágenes, lo que se hace es sustituir estas por el color medio de la entrada. Para FX-SHIELD estamos en el espacio de features, dónde los valores que van de $-\infty$ a ∞ . Por lo tanto hemos decidido sustituir dichos valores por 0. Suponiendo, sin pérdida de generalidad, que las características en z están ordenadas de menor importancia a mayor, se define $T_{fxshield}$ como:

$$z' = T_{fxshield}(z) = (0, 0, \dots, 0, z_{m+1}, \dots, z_{F_c})$$

Ahora podemos medir la predicción del modelo para este ejemplo modificado simplemente pasándolo por la cabeza de la red.

Ya estamos en condiciones de definir el factor de regularización que se utiliza en este método. Para un ejemplo x y unos parámetros Θ del modelo específicos, sean $y = f_{\Theta}(x) = l(z)$ la predicción original del modelo y $y' = l(T_{fxshield}(c_{\Theta}(x))) = l_{\Theta}(z')$ la predicción para el ejemplo con las características intermedias modificadas; entonces se tiene que:

4.3. MÉTODOS PROPUESTOS

$$FX - SHIELD(x, \Theta) = KL(y, y') + KL(y', y)$$

Dónde KL es la divergencia de Kullback-Leibler que se utiliza para medir la diferencia estadística entre las distribuciones de probabilidad entre los modelos. Luego estamos utilizando la diferencia divergencia de Kullback-Leibler simétrica. Utilizamos ésta porque es mejor para medir similitud entre dos distribuciones sin dar preferencia a ninguna.

Es decir, FX-SHIELD utiliza este valor regularizador en el entrenamiento por lo que en este método se minimiza la siguiente función:

$$coste_{fxshield}(\Theta, X, Y) = funcion_perdida(f_{\Theta}(X), Y) + FX - SHIELD(X, \Theta)$$

Una ventaja que presenta este método sobre X-SHIELD es que no necesita que el modelo de caja negra sea diferenciable, aunque sigue necesitando que la cabeza del modelo lo sea (para el cálculo de la importancia de las características). A cambio, FX-SHIELD no es totalmente agnóstico al modelo, pues es necesario poder extraer unas características intermedias.

Otra ventaja es que es más rápido que X-SHIELD ya que para el cálculo de la regularización no hace falta pasar las características enmascaradas por toda la red sino por las capas posteriores a las convolucionales, que suelen ser mucho más rápidas y con menos parámetros.

En X-SHIELD se esconden las características menos relevantes de la entrada a la red, que es una imagen, con la idea de eliminar partes de imagen que no son relevantes para la tarea de clasificación. En FX-SHIELD se esconden las características menos relevantes de las extraídas por las capas convolucionales. Esto puede ser interesante pues varios trabajos anteriores como (Bau, Zhou, Khosla, Oliva, y Torralba, 2017; Kim y cols., 2017; Olah, Mordvintsev, y Schubert, 2017) muestran que las capas intermedias en CNNs representan conceptos de alto nivel. Por lo tanto tiene sentido trabajar con estas características intermedias que codifican conceptos que tienen sentido para los humanos. Esto se puede ver como una ventaja de FXSHIELD sobre X-SHIELD (cuando se toman características de la imagen de entrada como una división de la imagen en cuadrados) ya que estas features intermedias pueden tener un mayor significado.

4.3.2. FR-Shield

FR-SHIELD (*Random FX-SHIELD*) es el mismo método que FX-SHIELD pero cambia en que las características que oculta se escogen de forma aleatoria sin tener en cuenta la importancia de éstas. Este método nos permite comparar FX-SHIELD con un método no informado. Además el hecho de que se oculten las características de forma aleatoria puede ayudar al modelo a no depender únicamente de las características más importantes y que las explicaciones estén apoyadas en más características. Finalmente este método se parece a *Dropout*, lo que también lleva a pensar que podría hacer que la red no sobreajuste.

4.3.3. H-Shield

Finalmente introducimos **H-SHIELD**, (*Hybrid X-SHIELD*) un método que combina X-SHIELD con FX-SHIELD. Para ello modificamos el valor regularizador para tener en cuenta ambos de la siguiente forma:

$$\begin{aligned} \text{coste_hshield}(\Theta, X, Y) = & \text{funcion_perdida}(f_{\Theta}(X), Y) + \\ & \alpha_1 \cdot X - \text{SHIELD}(X, \Theta) + \\ & \alpha_2 \cdot FX - \text{SHIELD}(X, \Theta), \end{aligned}$$

donde α_1, α_2 son dos parámetros positivos que utilizaremos para cambiar el peso que le damos a cada una de las regularizaciones por separado.

Con esta propuesta intentamos combinar las bondades de ambos métodos. El principal inconveniente de este método es su mayor coste computacional respecto a los métodos por separado. La determinación de los parámetros α_1 y α_2 se hará empíricamente comparando los valores de regularización individuales que se obtienen para cada método por separado. El porcentaje de elementos que se ocultan por cada método, que denotábamos como λ , ahora son dos parámetros distintos λ_1 y λ_2 , que serán dicho parámetro para X-SHIELD y FX-SHIELD respectivamente.

4.4. Implementación

Para la realización de este TFM se ha partido del [código](#) correspondiente al proyecto de X-SHIELD original ([Sevillano-García y cols., 2023b](#)). Éste está escrito en *Python*.

4.4. IMPLEMENTACIÓN

Se ha realizado un estudio de todo el código del proyecto original para entender correctamente cómo funciona y así poder implementar los nuevos métodos que proponemos. Además se han escrito varios *scripts* en *bash* para la ejecución de los entrenamientos de los modelos aplicando los distintos métodos de regularización en los servidores de GPUs de la UGR.

A continuación hacemos un resumen de todos los módulos del proyecto que se han utilizado, sin contar los *scripts* de *bash* de ejecución, y mencionamos cuando se han modificado para el TFM:

- **SHIELD/shield.py:** éste es el módulo más importante de todo. En él vienen las funciones para calcular las importancias de las características y las implementaciones de los distintos métodos. En particular se ha añadido a este archivo los métodos FX-SHIELD y FR-SHIELD.
- **procedures/cargar_datos.py:** este módulo es completamente nuevo y es necesario para cargar los datos del TFM en un *dataset* de *pytorch*. Este módulo se basa en la manera en la que se cargan los *datasets* utilizados en el trabajo original de X-SHIELD, cuya implementación se puede ver en el [GitHub](#) de las métricas REVEL.
- **procedures/procedures.py:** aquí vienen implementadas las funciones para cargar el modelo clasificador (*EfficientNet* en nuestro caso) y las funciones que realizan un paso de entrenamiento y validación.
- **tests/test.py y tests/train.py:** scripts para el entrenamiento de la red con X-SHIELD y para obtención de *accuracy* en test, respectivamente.
- **tests/mitrain.py, tests/mitest.py, tests/mitrain_hibrido.py:** los dos primeros son scripts para el entrenamiento de la red con X-SHIELD, FX-SHIELD o FR-SHIELD, y para obtención de *accuracy* en test, respectivamente. El tercero es una adaptación para entrenar H-SHIELD. Estos son muy parecidos a los anteriores pero están adaptados para utilizar nuestro conjunto de datos y los nuevos métodos.
- **tests/REVEL_metrics.py y tests/mi_REVEL_metrics.py:** *script* original para calcular las métricas REVEL para un modelo y la versión modificada para utilizar el conjunto de datos de este TFM.

Además durante la ejecución de los experimentos se disponía de una carpeta llamada **datosTFM** dónde había dos carpetas, **train** y **val** que contenían los datos de entrenamiento y test respectivamente.

CAPÍTULO 4. MÉTODOS

Para la gestión de paquetes de *Python* se ha utilizado la herramienta *Conda* que permite crearentornos con los paquetes de *Python* necesarios para el proyecto. Se ha utilizado la versión de *Conda* 4.10.1 y se ha creado un entorno con *Python* 3.9.23. Se han instalado los siguiente paquetes paquetes de *Python*:

- torch (versión 2.0.1): con CUDA versión 11.7
- torchvision
- tensorboard
- efficientnet_pytorch
- torchsummary
- numpy
- pandas
- scipy
- scikit-learn
- scikit-image
- matplotlib
- seaborn
- plotly
- tqdm
- opencv-python
- ipywidgets
- ipython
- wget
- captum
- revel-xai: paquete con la implementación de las métricas REVEL.

4.4. IMPLEMENTACIÓN

Todo el código desarrollado para el TFM está disponible en el siguiente [enlace](#).

5 Experimentos

5.1. Datos empleados

El conjunto de datos empleado está desarrollado por la iniciativa *al4HealthyAging*. En particular se creó para el paquete de trabajo 7: cribado y vigilancia activa en cánceres prevalente de la 3ª edad. Toda la metodología de la obtención de este conjunto de datos y la descripción del mismo proviene de un artículo interno que aún no se ha publicado.

Metodología de obtención y etiquetado de imágenes Para la obtención del conjunto de datos se siguió el procedimiento estándar de procesamiento hispatológico. Partían de muestras de prostatectomía radical (la extirpación completa de la próstata). A continuación la fijan en formalina. Tras esto un patólogo o residente de patología realiza un examen macróscopico para extraer muestras para estudiar con microscopio. Estas muestras de tejido se procesan deshidratándolos e impregnándolos en parafina. Luego se cortan secciones del tejido de entre $3\ \mu m$ y $5\ \mu m$. Después se colocan en láminas de vidrio y se tiñen con hemaxtoxilina-ecosina. Finalmente se cubren con otra lámina de vidrio para ser examinados con un microscopio.

A continuación las muestras se escanearon en un escáner de láminas, lo que produjo imágenes en formato *TIFF*. Dichas imágenes fueron segmentadas manualmente por patólogos profesionales del servicio de anatomía patológica del Hospital Miguel Servet de Zaragoza (ver Figura 5.1). Los diferentes segmentos fueron anotados como pertenecientes a una de las 14 clases posibles, presentes en la Tabla 5.1. Para llevar a cabo el etiquetado hicieron uso de la plataforma *Cytomine*.

Finalmente las imágenes se fragmentan en parches de tamaño 224×224 píxeles. Cuando cuando un parche contiene una proporción de píxeles perteneciente a una clase superando el umbral $h = 0.75$ este parche se anota con dicha clase, si esto no ocurre para ninguna clase se descarta el parche.

Esta es la versión del conjunto de datos con el que partimos nosotros, tenemos los

CAPÍTULO 5. EXPERIMENTOS

parches que han sido anotados con una de las 14 clases.

Nombre	Descripción	Tipo
Tejido sano diferente a estroma (HT)	Tejido sano sin estructuras relevantes asociadas a malignidad	Tejido no maligno
Estroma sano (HS)	Estroma sin estructuras relevantes asociadas a malignidad	Tejido no maligno
Glándulas no neoplásicas (NG)	Glándulas con morfología no neoplásica	Tejido no maligno
Tejido inflamatorio (IT)	Tejido con signos de inflamación	Tejido no maligno
Gleason 3 (G3)	Glándulas individuales, bien formadas, de tamaño variable, separadas por estroma	Tejido maligno
Gleason 4, patrón cribiforme (G4c)	Glándulas compuestas por células tumorales dispuestas en trabéculas redondeadas o irregulares, cohesivas, con perforaciones o luces perforadas	Tejido maligno
Gleason 4, patrón glándulas fusionadas (G4f)	Glándulas sin estroma entre ellas, con luz glandular conservada	Tejido maligno
Gleason 4, patrón glándulas pobremente formadas (G4p)	Glándulas pequeñas con luces desproporcionadas	Tejido maligno
Gleason 4, patrón glomeruloide (G4g)	Glándulas con un nido de células tumorales que ocupa la luz y está unida a la glándula por un polo	Tejido maligno
Gleason 5, patrón comedonecrosis (G5c)	Nidos tumorales redondeados con necrosis central de tipo comedo	Tejido maligno
Gleason 5, patrón sin glándulas definidas (G5w)	Células tumorales sueltas, en hilera o trabéculas. Ausencia de diferenciación glandular	Tejido maligno
Neoplasia intraepitelial prostática de alto grado (PIN)	Glándulas con capa basal y proliferación de células epiteliales con atipia y pérdida de mucosecreción; patrones micropapilar, cribiforme, plano, hiperplásico	Tejido maligno
Adenocarcinoma ductal (DA)	Glándulas cribiformes y estructuras papilares y/o complejas revestidas por células altas columnares pseudoestratificadas	Tejido maligno

Continúa en la siguiente página

5.1. DATOS EMPLEADOS

Tabla 5.1 – continuación

Nombre	Descripción	Tipo
Carcinoma intraductal (IC)	Grandes ductos con capa basal y luz dilatada, distendida y ocupada por proliferación de células epiteliales con marcada atipia y crecimiento papilar, cribiforme laxo o cribiforme denso	Tejido maligno

Tabla 5.1: En esta tabla se muestra la clasificación, descripción y malignidad de los tejidos presentes en el conjunto de datos. Tabla extraída y adaptada del artículo aún no publicado mencionado al inicio del capítulo.




Figura 5.1: Imagen de tejido segmentado. Imagen extraída del artículo mencionado al inicio del capítulo.

Distribución de los datos En total, el conjunto de datos contiene 126.109 imágenes anotadas. La distribución de estos entre las distintas clases se muestra en la Figura 5.2. Se puede apreciar un claro desbalanceo en los datos. La clase menos frecuente es Gleason 4 glomeruloide (G4p) con 243 datos (0.19 % de los datos), mientras que la más frecuente es Glándulas no neoplásticas (NG) con 35.894 datos (28.46 % de los datos).

CAPÍTULO 5. EXPERIMENTOS




Figura 5.2: Distribución de las imágenes del conjunto de datos según su clase.




Figura 5.3: Distribución de las imágenes del conjunto de datos para entrenamiento y para test según su clase.

5.2. Experimentación

Los experimentos han sido ejecutados en los servidores de cómputo Atenea y Hera, de los servidores NGPU de la Universidad de Granada. Las gráficas utilizadas son GTX Titan Xp con 128 Gb DDR4 y Titan RTX con 128 Gb DDR4, respectivamente.

5.2.1. Separación de datos

Los datos están divididos en dos conjunto bien diferenciados, *train* y *val*. El conjunto de *train* contiene 113.491 imágenes (90 % de los datos) mientras que *val* contiene las 12.618 imágenes restantes (10 % de los datos). Esta partición de los datos se realizó para entrenamiento/test de los modelos y es la que vamos a utilizar. Se puede comprobar que esta partición de los datos mantiene la proporción estratificada de las clases como se puede ver en la Figura 5.3.

Los modelos se van a entrenar con el conjunto de entrenamiento y se evaluará con los datos del conjunto de test. Esta división de los datos se realiza para tener un conjunto, el de test, que no haya visto el modelo durante el entrenamiento para evaluar el rendimiento real del modelo para datos que aún no ha visto. Esta práctica se utiliza comúnmente para evitar el sobreentrenamiento de la red. La división de 90/10 es adecuada para nuestro conjunto de datos porque disponemos de una cantidad muy grande de datos (126.109 imágenes).

Validacion Teniendo en cuenta el tamaño de nuestro conjunto de datos y de los recursos computacionales de los que disponemos hemos decidido utilizar un conjunto de validación fijo.

Esta técnica consiste en separa un porcentaje del conjunto de entrenamiento para no entrenar con él. Sin embargo se va a utilizar para evaluar el modelo al final de cada época, calculando su función de error sobre este conjunto. Esta técnica es relevante para el entrenamiento del modelo porque cumple un rol distinto a los conjuntos de entrenamiento y test. Este nos ayudará a realizar un ajuste de hiperparámetros del modelo y ayuda a prevenir el sobreajuste, eligiendo el modelo que menor error tenga en validación, en vez de en entrenamiento.

Nosotros vamos a dividir el conjunto de entrenamiento en 90/10 para entrenamiento y para validación respectivamente. En la Figura 5.4 presentamos un esquema con la división del conjunto de datos seguida para los experimentos.




Figura 5.4: Distribución de los datos en los conjuntos finales de entrenamiento, validación y test.

5.2.2. Elección de hiperparámetros

El **optimizador** elegido para entrenar el modelo es Adam (Kingma y Ba, 2017), que es una modificación de SGD. Se ha elegido este optimizador porque es el que se utilizó originalmente en el artículo de X-SHIELD (Sevillano-García y cols., 2023b) y porque está probado empíricamente que tiene mejor rendimiento que el resto de optimizadores para una gran variedad de tareas.

Cómo *learning rate* inicial Adam se ha escogido el valor 0.0004. Un *learning rate* inicial es muy determinante porque dicta como converge el modelo. Para la elección de este parámetro se han hecho pruebas iniciales sobre los modelos y hemos determinado que este valor es el que mejor convergencia daba al modelo.

El tamaño del *minibatch* escogido ha sido 32. En (Smith, Kindermans, Ying, y Le, 2018) se ve que tamaños grandes de *minibatches* acelera el entrenamiento y estabiliza la convergencia del modelo mientras que un tamaño pequeño puede mejorar la capaz de generalizar del modelo. Por esto hemos decidido escoger tamaño 32 ya que es el mayor tamaño de *minibatch* para el que la gráfica dónde ejecutamos los experimentos no se quedaba sin memoria.

Para el número de **épocas** hemos escogido 24. Esta decisión la tomamos por los recursos computacionales de los que disponemos. Por ello se hicieron pruebas experimentales previas para buscar un valor que garantizaba la convergencia de estos pero no se excedía en tiempo de entrenamiento. El número de épocas es por lo tanto 24. Con este número de épocas los modelos entrenados tardan hasta un día en ser

entrenados.

Cómo ya sabemos el modelo que vamos a utilizar en los experimentos es EfficientNet-B2 con entradas de tamaño 224×224 . Este modelo lo cargamos de la librería de *pytorch*. Además lo vamos a cargar con los pesos preentrenados de esta red sobre el conjunto de datos IMAGENET-1K lo que se conoce como *transfer learning* y nos permite comenzar el entrenamiento con un modelo cuyas características ya tienen cierto entrenamiento.

En primer lugar vamos a entrenar el modelo EfficientNet-B2 base con los parámetros que hemos especificado. Después se entrenará esta red aplicando los distintos métodos de regularización explicados, estos son: el método original con el que comparamos los propuestos (X-SHIELD) y los métodos nuevos que proponemos en este trabajo (FX-SHIELD, FR-SHIELD y H-SHIELD).

Los hiperparámetros a los que se va a probar a cambiar sus valores son los correspondientes a los métodos de regularización de XAI. Estos son:

- λ : En el caso de X-SHIELD, FX-SHIELD y FR-SHIELD este parámetro determina que porcentaje de las características (de las entrada en el caso de X-SHIELD y los intermedios en el caso de los nuestros) se van a ocultar para el cálculo de los valores de regularización. Para X-SHIELD se ha probado con los parámetros 3, 6, 9 y 12, ya que en (Sevillano-García y cols., 2023b) se demostró que funcionaba mejor para valores similares a estos. Para los métodos nuevos, como no tenemos esta información hemos probado con más variedad de valores. Para FX-SHIELD hemos probado con los parámetros a 3, 6, 9, 12, 25, 35, 45, 55, 65, 75 y 85, como funcionaba mejor para 75 también probamos con los valores vecinos 70, 73 y 77. Para FR-SHIELD hemos probado con 3, 45, 65 y 75. Hemos decidido probar con menos valores y más dispersos pues este presenta una mayor aleatoriedad en su comportamiento experimental y una exploración más fina eleva el riesgo de sobreajustar a ruido.
- α_1 y α_2 : Estos son los parámetros para H-SHIELD. Son los pesos que se aplican a la regularización X-SHIELD y FX-SHIELD respectivamente. Para los hiperparámetros λ para cada uno de estos hemos escogido los que mejores resultados daban por individual que son 12 y 77 respectivamente. Para (α_1, α_2) se han probado (1,1), (1,2) y (1,3)

Además para las características de X-SHIELD se divide la imagen de entrada en 64 cuadrados del mismo tamaño para cada imagen como se hace en (Sevillano-García y

cols., 2023b).

De esta manera, el modelo se entrena aplicando cada método con la distintas elecciones de hiperparámetros. Para evitar el sobreentrenamiento, durante el entrenamiento de los modelos en cada época se calcula la función de pérdida sobre el conjunto de validación y el modelo final del entrenamiento es el que menor pérdida en validación haya obtenido, no necesariamente el que minimice el error en entrenamiento.

Para elegir los mejores hiperparámetros para cada método se escoge modelo entrenado que minimicen la *accuracy* en validación para dichos hiperparámetros.

5.3. Métricas

Para el entrenamiento del modelo se utiliza como función de pérdida el **error de entropía cruzada** que es la función de pérdida que se utiliza habitualmente para entrenar redes neuronales en clasificación.

La *accuracy* es una métrica que mide la proporción de elementos bien clasificados, por lo tanto se valor se encuentra en el rango $[0, 1]$, siendo 0 si no clasifica bien ningún elemento y 1 si clasifica bien todos. Para evaluar el rendimiento del modelo en la tarea de clasificación utilizamos la métrica de *accuracy*.

Por otro lado para evaluar el rendimiento utilizamos la métricas **REVEL**. Recordamos que estas son: *local concordance*, *local fidelity*, *prescriptivity*, *conciseness* y *robustness*. Para cada método de regularización las obtenemos para el modelo final que ha sido calculado para los mejores parámetros de dicho método.

Para el cálculo de estas métricas, se generan explicaciones con un generador de LLEs. Elegimos LIME por los resultados presentados en (Sevillano-García y cols., 2023a), donde este obtiene mejores resultados que SHAP. Utilizamos las mismas características que X-SHIELD para LIME, es decir, 64 cuadrados del mismo tamaño sobre la imagen de entrada. Para los cálculos de la explicación de un ejemplo, utilizamos la siguiente configuración REVEL: generamos 1000 vecinos. El parámetro σ (explicado en la subsección 2.3.1) lo ponemos a 12.

Para cada ejemplo, generamos 10 explicaciones para el cálculo de las cuatro primeras métricas y calculamos la media aritmética de cada una para obtener su valor final para ese ejemplo. En total utilizamos 100 ejemplos. Para el cálculo de la *robustness* utilizan las 10 explicaciones generadas para las otras métricas para calcular esta

métrica. Hemos elegido estos parámetros para calcular estas métricas por límites de coste computacional. El cálculo de estas métricas para un modelo ya entrenado tarda alrededor de 1 día.

Test estadísticos bayesianos Una vez tenemos los 100 valores de las métricas REVEL para cada método utilizamos los tests estadísticos bayesianos, estos se encuentran implementados en la librería de *Python* [baycomp](#). Esta biblioteca introduce los tests bayesianos para comparación de método. Estos tests permiten comparar dos métodos de manera probabilística, estimando directamente la probabilidad de que uno sea mejor que otro, o que la diferencia entre ellos sea significativamente relevante.

Los tests bayesianos se basan en la estimación de la distribución posterior de la diferencia de desempeño entre dos métodos. Se calculan las tres probabilidades siguientes:

- Método A es mejor que método B.
- Método B es mejor que método A.
- Diferencia es irrelevante (*Region of Practical Equivalence*, ROPE)

ROPE define un umbral de diferencia prácticamente insignificante. En la página del propio método recomienda $ROPE = 0.01$ para métricas en el rango $[0, 1]$ que es el caso de las métricas REVEL (técnicamente *robustness* podría ser negativa, en la práctica suele estar en el rango).

Diremos que un método es mejor que otro para una métrica cuando la probabilidad de que sea mejor es $> 95\%$. Además de los test mostraremos las gráficas de violin para las distintas métricas y métodos. En particular compararemos: FX-SHIELD con X-SHIELD, porque X-SHIELD es un método probado que mejora el rendimiento de las métricas REVEL, FX-SHIELD con FR-SHIELD, para ver como influye ocultar características aleatorias y FX-SHIELD con HSHIELD, para ver como se comparan estos dos métodos nuevos.

5.4. Resultados

En esta sección vamos a presentar los resultados obtenidos. En primer lugar comentaremos los resultados sobre el entrenamiento del modelos con las distintas regularizaciones, introduciremos las curvas de aprendizaje y compararemos los resultados

CAPÍTULO 5. EXPERIMENTOS

obtenidos para distintos hiperparámetros. En segundo lugar veremos los resultados obtenidos para las métricas REVEL y compararemos los métodos utilizando tests estadísticos. Finalmente realizaremos una discusión general de los resultados.

5.4.1. Entrenamiento y accuracy

En esta subsección introducimos los resultados obtenidos en los entrenamientos utilizando cada método con todos los distintos hiperparámetros utilizados. Tras esto, comentaremos los resultados para el conjunto test de cada método con sus mejores hiperparámetros. Finalmente, haremos un estudio del comportamiento de las curvas de aprendizaje para cada regularización.

Los resultados de todas las redes entrenadas con los distintos métodos y para todas las combinaciones de hiperparámetros se encuentran en la Tabla 5.2. En esta se puede ver que hiperparámetros son los que presentan un mejor rendimiento para cada modelo, es decir, con qué parámetros han conseguido la mejor *accuracy* en el conjunto de validación.

Es destacable que para FX-SHIELD se obtiene el mejor resultado para $\lambda = 77$ mientras que para FR-SHIELD alcanza su mejor rendimiento con $\lambda = 3$. En H-SHIELD la mejor *accuracy* se alcanza cuando se combinan X-SHIELD y FX-SHIELD con el mismo peso. Por otro lado X-SHIELD obtiene su mejor rendimiento con $\lambda = 12$ y es el que mejor *accuracy* en validación obtiene de todos, aunque por un margen del 1 %.

Más allá de comparar modelos de forma aislada, los resultados muestran un patrón consistente respecto al efecto de las distintas regularizaciones. En general, al aumentar el valor de λ (o α_2 en H-SHIELD) se observa una ligera degradación en la *accuracy* de entrenamiento y un incremento en el valor de regularización, esto indica un mayor control del sobreajuste. En FR-SHIELD valores altos de λ penalizan fuertemente el entrenamiento, con un rápido aumento en la regularización. En contraste, FX-SHIELD es más robusto, manteniendo un desempeño estable incluso para λ grandes.

5.4. RESULTADOS

Modelo	Tr/Ac	Tr/Los	Tr/Re	Val/Ac	Val/Los	Val/Re
Baseline	0.994	0.00060	0.0000	0.957	0.00601	0.0000
X-SHIELD ($\lambda = 3.0$)	0.985	0.00136	0.001278	0.958	0.00442	0.000167
X-SHIELD ($\lambda = 6.0$)	0.983	0.00157	0.001400	0.956	0.00464	0.000549
X-SHIELD ($\lambda = 9.0$)	0.980	0.00183	0.001541	0.954	0.00453	0.000660
X-SHIELD ($\lambda = 12.0$)	0.981	0.00175	0.001533	0.959	0.00419	0.001043
FR-SHIELD ($\lambda = 3.0$)	0.994	0.00057	0.000637	0.957	0.00600	0.000042
FR-SHIELD ($\lambda = 45.0$)	0.993	0.00064	0.004487	0.956	0.00658	0.002367
FR-SHIELD ($\lambda = 65.0$)	0.993	0.00068	0.018442	0.953	0.00739	0.011644
FR-SHIELD ($\lambda = 75.0$)	0.992	0.00075	0.046440	0.956	0.00657	0.030981
FX-SHIELD ($\lambda = 3.0$)	0.994	0.00059	0.000187	0.956	0.00664	0.000005
FX-SHIELD ($\lambda = 6.0$)	0.994	0.00057	0.000192	0.952	0.00705	0.000007
FX-SHIELD ($\lambda = 9.0$)	0.995	0.00053	0.000188	0.956	0.00639	0.000010
FX-SHIELD ($\lambda = 12.0$)	0.994	0.00060	0.000207	0.956	0.00643	0.000014
FX-SHIELD ($\lambda = 25.0$)	0.994	0.00060	0.000212	0.953	0.00661	0.000018
FX-SHIELD ($\lambda = 35.0$)	0.993	0.00060	0.000213	0.955	0.00622	0.000021
FX-SHIELD ($\lambda = 45.0$)	0.993	0.00069	0.000237	0.954	0.00681	0.000029
FX-SHIELD ($\lambda = 55.0$)	0.992	0.00072	0.000250	0.954	0.00648	0.000027
FX-SHIELD ($\lambda = 65.0$)	0.992	0.00076	0.000268	0.953	0.00673	0.000028
FX-SHIELD ($\lambda = 70.0$)	0.992	0.00078	0.000278	0.954	0.00624	0.000029
FX-SHIELD ($\lambda = 73.0$)	0.992	0.00074	0.000272	0.952	0.00656	0.000032
FX-SHIELD ($\lambda = 75.0$)	0.992	0.00079	0.000272	0.956	0.00615	0.000024
FX-SHIELD ($\lambda = 77.0$)	0.991	0.00083	0.000302	0.958	0.00635	0.000025
FX-SHIELD ($\lambda = 85.0$)	0.991	0.00088	0.000339	0.954	0.00653	0.000033
H-SHIELD ($\alpha_1 = 1, \alpha_2 = 1$)	0.973	0.00249	0.001862	0.954	0.07226	0.015705
H-SHIELD ($\alpha_1 = 1, \alpha_2 = 2$)	0.965	0.00328	0.002162	0.948	0.08392	0.015020
H-SHIELD ($\alpha_1 = 1, \alpha_2 = 3$)	0.953	0.00434	0.002547	0.948	0.08334	0.018308

Tabla 5.2: Resultados de entrenamiento y validación para diferentes métodos. Para cada método se muestran su error, valor de regularización y *accuracy* en entrenamiento y validación. Para cada método se ha puesto en negrita el modelo que mejor *accuracy* obtiene en validación que se considera el mejor modelo con dicho método.

CAPÍTULO 5. EXPERIMENTOS

En la Tabla 5.3 tenemos los valores obtenidos en test para los mejores modelos de cada método. X-SHIELD mejora la *accuracy* del modelo *baseline*, en este caso en 0.07. Luego es una mejora significativa. Por otro lado el método híbrido H-SHIELD consigue capturar esta mejoría, empeorando únicamente en un 0.01 su *accuracy* respecto de X-SHIELD. Por otro lado los métodos FX-SHIELD y FR-SHIELD no han conseguido mejorar al modelo base, obteniendo ambas 0.949 de *accuracy*, prácticamente la misma que el modelo base (un 0.01 de diferencia a favor del modelo base). Observemos también que H-SHIELD tiene con diferencia el mayor valor de su función de regularización en test a pesar de ser la suma de X-SHIELD y FX-SHIELD. Esto parece indicar que H-SHIELD no es capaz de minimizar ambos valores de regularización al mismo tiempo.

Modelo	Test/Acc	Test/Loss	Test/Reg
Baseline	0.950	0.005000	0.000
X-SHIELD ($\lambda = 12.0$)	0.957	0.004000	0.001
FR-SHIELD ($\lambda = 3.0$)	0.949	0.005000	0.000
FX-SHIELD ($\lambda = 77.0$)	0.949	0.005295	0.000064
H-SHIELD ($\alpha_1 = 1.0, \alpha_2 = 1.0$)	0.956	0.071610	0.015749

Tabla 5.3: Resultados de los mejores modelos en test. Se muestra la *accuracy*, la pérdida y el valor de regularización.

En la Figura 5.5 se encuentran las curvas de aprendizaje de X-SHIELD para sus distintos parámetros. Se observa un comportamiento natural de convergencia de la red: la función de pérdida en entrenamiento continúa disminuyendo mientras que, en comparativa, la de validación se estabiliza. Cabe destacar que aunque en validación los valores de regularización siguen un orden y parecen converger a valores distintos (mayor cuanto mayor es el λ) lo cual es esperable, en entrenamiento estos convergen a valores muy cercanos.

5.4. RESULTADOS




Figura 5.5: Evolución de métricas para el modelo X-SHIELD

En las curvas de aprendizaje de FX-SHIELD (Figura 5.6) se observa un comportamiento normal. Al igual que ocurría con X-SHIELD sus valores de regularización convergen todos a valores muy cercanos en entrenamiento. Por otro lado, esto también ocurre con sus valores de regularización. Podemos ver que la función de pérdida en entrenamiento converge correctamente y en validación este método necesita menos épocas para aprender ya que el valor en validación de la pérdida empieza a aumentar ligeramente (aunque la métrica de precisión en validación sigue mejorando). Esto no afecta a nuestros resultados porque el modelo final es el que mejor pérdida obtuvo en validación, no el de la última época.

En la Figura 5.7, observamos la evolución de las métricas para el modelo FX-SHIELD. Se observa que ocurre lo mismo para la función de pérdida que para FX-SHIELD. Por otra parte este no es capaz de minimizar la regularización en entrenamiento y validación, especialmente para valores altos de λ . Esto podría ser causado por la naturaleza aleatoria de esta regularización.

CAPÍTULO 5. EXPERIMENTOS




Figura 5.6: Evolución de métricas para el modelo FX-SHIELD




Figura 5.7: Evolución de métricas para el modelo FRSHIELD

Finalmente para H-SHIELD (Figura 5.8) se obtienen resultados parecidos a X-SHIELD. Observando su gráfica de pérdida en entrenamiento y en validación se que este método también podría beneficiarse de entrenar durante más épocas.

5.4. RESULTADOS




Figura 5.8: Evolución de métricas para el modelo HSHIELD

5.4.2. Métricas REVEL

En esta subsección nos centramos en evaluar la calidad de las explicaciones generadas por los distintos métodos a través de las métricas REVEL. Para ello se analizan las distribuciones obtenidas mediante gráficos de violín, lo que permite comparar visualmente el comportamiento de cada regularización para las distintas métricas. Después realizamos test bayesianos para realizar una comparación estadística de los resultados obtenidos.

Vemos en la Figura 5.9 como se distribuyen las 100 medidas por métrica REVEL para cada método. Los métodos FX-SHIELD, X-SHIELD y H-SHIELD tienen distribuciones casi idénticas para la *local concordance* y para la *local fidelity*. Tienen distribuciones muy concentradas al valor máximo. Por otro lado FR-SHIELD tiene una distribución parecida pero menos concentrada, con mayor varianza.

X-SHIELD y H-SHIELD tienen una distribución de la *Robustness* parecida, con H-SHIELD un poco mayor. Para FX-SHIELD esta es claramente más baja. FR-SHIELD presenta la peor distribución de los cuatro métodos con mayor varianza.

De los gráficos de violín de la concisión no se puede discernir nada con una inspección visual excepto que la distribución para FR-SHIELD es muy distinta a la de los otros métodos.

CAPÍTULO 5. EXPERIMENTOS

Por último, para la prescriptividad se tienen dos distribuciones parecidas para X-SHIELD y H-SHIELD, estando la de X-SHIELD desplazada hacia valores altos. Por otro lado se tienen la de FX-SHIELD y FR-SHIELD que son parecidas también. A simple vista no podemos cercionarnos de si hay diferencias significativas entre ambas distribuciones.




Figura 5.9: *Violin plots* para las métricas de evaluación de explicaciones REVEL obtenidas para los modelos entrenados con las regularizaciones X-SHIELD, FX-SHIELD, FR-SHIELD y H-SHIELD.

5.4. RESULTADOS

Los últimos resultados obtenidos vienen de los test bayesianos que hemos realizado sobre estas métricas. En la Tabla 5.4 se tiene que para la concordancia local y la fidelidad local de los métodos X-SHIELD y FX-SHIELD son iguales. Además FX-SHIELD mejora la *prescriptivity* y la *conciseness*, aunque esta última sin una diferencia estadísticamente significativa. De la misma forma, X-SHIELD presenta una mejor *robustness*.

Para las comparaciones entre FX-SHIELD y FR-SHIELD (Tabla 5.5) tenemos que una vez más la *local concordance* y la *local fidelity* de ambos métodos coinciden completamente. FX-SHIELD mejora la *conciseness* y *prescriptivity* de FR-SHIELD, aunque únicamente con diferencia estadísticamente significativa en la primera. Por último ambas coinciden en su rendimiento en *robustness*.

El último test realizado es entre FX-SHIELD y H-SHIELD (Tabla 5.6). Otra vez ocurre que para la *local concordance* y la *local fidelity* de ambos métodos son iguales. FX-SHIELD mejora la *prescriptivity* y la *conciseness*, aunque esta última sin una diferencia estadísticamente significativa (pero muy alta igualmente). H-SHIELD mejora en *robustness* de manera significativa a FX-SHIELD.

Métrica	P(X-Shield > FX-Shield)	P(=)	P(FX-Shield > X-Shield)
Local Fidelity	0.00 %	100.00 %	0.00 %
Local Concordance	0.00 %	100.00 %	0.00 %
Conciseness	29.34 %	0.00 %	70.66 %
Prescriptivity	1.23 %	0.00 %	98.77 %
Robustness	68.33 %	31.67 %	0.00 %

Tabla 5.4: Resultados de los tests bayesianos entre X-Shield y FX-Shield.

Métrica	P(FX-Shield > FR-Shield)	P(=)	P(FR-Shield > FXShield)
Local Fidelity	0.00 %	100.00 %	0.00 %
Local Concordance	0.00 %	100.00 %	0.00 %
Conciseness	98.31 %	0.00 %	1.69 %
Prescriptivity	77.69 %	0.00 %	22.31 %
Robustness	12.28 %	87.72 %	0.00 %

Tabla 5.5: Resultados de los tests bayesianos entre FX-Shield y FR-Shield.

Métrica	P(FX-Shield > H-Shield)	P(=)	P(H-Shield > FX-Shield)
Local Fidelity	0.00 %	100.00 %	0.00 %
Local Concordance	0.00 %	100.00 %	0.00 %
Conciseness	83.28 %	0.00 %	16.72 %
Prescriptivity	99.99 %	0.00 %	0.01 %
Robustness	0.00 %	1.29 %	98.71 %

Tabla 5.6: Resultados de los tests bayesianos entre FX-Shield y H-Shield.

5.5. Discusión

Respecto al entrenamiento de los modelos el punto principal es que tanto X-SHIELD como H-SHIELD se podrían beneficiar de un mayor número de épocas.

Por otro lado hemos visto que X-SHIELD y H-SHIELD son regularizaciones centradas en mejorar la interpretabilidad del modelo que además consiguen una mejora en el rendimiento en clasificación. Sin embargo los métodos FX-SHIELD y FR-SHIELD mantienen prácticamente intacto este aspecto del modelo, aunque esto de por sí se puede considerar un aspecto positivo de estos ya que muchos métodos utilizados en XAI empeoran tienen un coste en el rendimiento a cambio de mejora de la interpretabilidad.

En cuanto a explicabilidad, el método propuesto FX-SHIELD es una versión mejor de FR-SHIELD. Esto se podría deber a que FR-SHIELD es una versión estocástica que FX-SHIELD. Por otro lado FX-SHIELD produce explicaciones más interpretables que X-SHIELD, aunque menos robustas. Por otro lado X-SHIELD mejora el rendimiento del modelo en la tarea de clasificación, mejorando la *accuracy* en test. Nuestro último método propuesto H-SHIELD, que combina los métodos X-SHIELD y FX-SHIELD consigue capturar las ventajas de X-SHIELD (mejor *accuracy* y mayor *robustness*) pero no es capaz de mejorar a FX-SHIELD en el resto de métricas REVEL, sin embargo, es capaz de mejorar la robustez de las explicaciones respecto al método X-SHIELD. Además todos los métodos con los que hemos experimentado aseguran un mínimo de calidad en sus explicaciones al tener las métricas de *local fidelity* y *local concordance* de alta calidad, con distribuciones muy concentradas alrededor del máximo.

6 Conclusiones

En este trabajo nos hemos centrado en el problema de mejorar la interpretabilidad de modelos de clasificación de lesiones cancerosas en biopsias de próstata utilizando técnicas de IA explicable. Para el desarrollo de este, lo dividimos en objetivos más pequeños que hemos cumplido a lo largo del trabajo. En primer lugar realizamos una revisión del estado del arte de los distintos métodos necesarios para abordar el problema principal: modelos de clasificación, de métodos de XAI para generación de explicaciones, métodos de XAI para la mejora de explicaciones y métricas XAI que midan aspectos cuantitativos de los distintos métodos propuestos. A continuación, realizamos un estudio del código de la regularización X-SHIELD (Sevillano-García y cols., 2023b), método del que parten los que proponemos nosotros, y las métricas REVEL (Sevillano-García y cols., 2023a), que son las que utilizamos para comparar los distintos métodos. Después, presentamos en detalle nuestros métodos originales: FX-SHIELD, FR-SHIELD y H-SHIELD, tres regularizaciones de la familia T-SHIELD. Tras implementarlos, diseñamos los distintos experimentos. Finalmente, ejecutamos estos experimentos, evaluamos los resultados obtenidos y discutimos su significado.

Nuestro método FX-SHIELD mejora al método del estado del arte X-SHIELD en dos de las cinco métricas REVEL, consigue el mismo rendimiento en otras dos métricas y empeora levemente la *robustness*. Además, FX-SHIELD mantiene la *accuracy* obtenida por el modelo base. Podemos afirmar que FX-SHIELD muestra ventajas de interpretabilidad sobre X-SHIELD. Por otro lado, también hemos visto que FX-SHIELD muestra un mejor comportamiento que FR-SHIELD, pues para cada métrica REVEL lo mejora o iguala, destacando lo importante que es que las características enmascaradas por FX-SHIELD sean las de menor importancia. Nuestro último método, H-SHIELD, que combina FX-SHIELD y X-SHIELD tiene un rendimiento parecido a X-SHIELD en las métricas REVEL y también en *accuracy*.

Por todo lo expuesto anteriormente, podemos afirmar que se ha conseguido el objetivo final del TFM, pues hemos presentado un método de regularización XAI novedoso que mejora las explicaciones obtenidas en dos de las cinco métricas REVEL respecto al método del estado del arte y lo hemos aplicado a un modelo de clasificación de lesiones cancerosas en biopsias de próstata para mejorar su interpretabilidad.

CAPÍTULO 6. CONCLUSIONES

Para el desarrollo de este TFM, se ha utilizado principalmente conocimientos adquiridos durante el Máster Universitario en Ciencia de Datos e Ingeniería de Computadores. También se ha aprendido a utilizar en más profundidad la librería fundamental para aprendizaje profundo *Pytorch* y el gestor de paquetes *Conda*.

Finalmente presentamos varias líneas posibles para posibles trabajos futuros. En primer lugar, sería interesante probar FX-SHIELD y X-SHIELD con distintos conjuntos de datos, modelos y LLEs, con el fin de obtener más evidencia sobre la calidad de las explicaciones producidas por nuestro método y de como se comparan con las de X-SHIELD. En segundo lugar, sería valioso estudiar otras formas más sofisticadas de combinar FX-SHIELD y X-SHIELD que el método H-SHIELD propuesto, para intentar conseguir que las bondades que presentan ambos se combinen. Por ejemplo, un método que calcule la importancia de las características de la entrada e intermedias, tras lo que hace un paso por la red del dato perturbado ocultando también las características intermedias. Finalmente, proponemos buscar mecanismos que aumenten la generalización del modelo cuando se entrene con FX-SHIELD para desarrollar un método que mejore interpretabilidad y poder de clasificación simultáneamente.

Bibliografía

- Abu-Mostafa, Y. S., Magdon-Ismail, M., y Lin, H.-T. (2012). *Learning from data*. AML-Book.
- Achtibat, R., Dreyer, M., Eisenbraun, I., Bosse, S., Wiegand, T., Samek, W., y Lapuschkin, S. (2023). From attribution maps to human-understandable explanations through concept relevance propagation. *Nature Machine Intelligence*, 5(9), 1006–1019. Descargado de <https://doi.org/10.1038/s42256-023-00711-8> doi: 10.1038/s42256-023-00711-8
- Ali, S., Abuhmed, T., El-Sappagh, S., Muhammad, K., Alonso-Moral, J. M., Confalonieri, R., ... Herrera, F. (2023). Explainable artificial intelligence (xai): What we know and what is left to attain trustworthy artificial intelligence. *Information Fusion*, 99, 101805. Descargado de <https://www.sciencedirect.com/science/article/pii/S1566253523001148> doi: <https://doi.org/10.1016/j.inffus.2023.101805>
- Alpaydin, E. (2020). *Introduction to Machine Learning*. MIT Press. Descargado de <https://books.google.es/books?id=4j9GAQAIAAJ>
- Amparore, E. G., Perotti, A., y Bajardi, P. (2021). To trust or not to trust an explanation: using leaf to evaluate local linear xai methods. *PeerJ Computer Science*, 7. Descargado de <https://api.semanticscholar.org/CorpusID:234359251>
- Barredo Arrieta, A., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., ... Herrera, F. (2020). Explainable artificial intelligence (xai): Concepts, taxonomies, opportunities and challenges toward responsible ai. *Information Fusion*, 58, 82–115. doi: <https://doi.org/10.1016/j.inffus.2019.12.012>
- Bau, D., Zhou, B., Khosla, A., Oliva, A., y Torralba, A. (2017). Network dissection: Quantifying interpretability of deep visual representations. *CoRR*, abs/1704.05796. Descargado de <http://arxiv.org/abs/1704.05796>
- Bishop, C. (1995). *Neural networks for pattern recognition*. Oxford university press.
- Bishop, C. (2006). *Pattern recognition and machine learning*. Springer.
- Bishop, C. M., y Bishop, H. (2023). *Deep learning: Foundations and concepts*. Springer Nature.
- Deng, L. (2012). The mnist database of handwritten digit images for machine learning research. *IEEE Signal Processing Magazine*, 29(6), 141–142.

Bibliografia

- Ding, M., Xiao, B., Codella, N., Luo, P., Wang, J., y Yuan, L. (2022). Davit: Dual attention vision transformers. En S. Avidan, G. Brostow, M. Cissé, G. M. Farinella, y T. Hassner (Eds.), *Computer vision – eccv 2022* (pp. 74–92). Cham: Springer Nature Switzerland.
- Epstein, J. I., Amin, M. B. M., Reuter, V. E., y Humphrey, P. A. (2017). Contemporary gleason grading of prostatic carcinoma: An update with discussion on practical issues to implement the 2014 international society of urological pathology (isup) consensus conference on gleason grading of prostatic carcinoma. *The American Journal of Surgical Pathology*. doi: 10.1097/PAS.0000000000000820
- Goodfellow, I., Bengio, Y., y Courville, A. (2016). *Deep learning*. MIT Press.
- H, S., J, F., RL, S., M, L., I, S., A, J., y F, B. (2021). Global cancer statistics 2020: Globocan estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA: A Cancer Journal for Clinicians*. doi: 10.3322/caac.21660
- Haykin, S. (1998). *Neural networks: A comprehensive foundation* (segunda ed.). USA: Prentice Hall PTR.
- He, K., Zhang, X., Ren, S., y Sun, J. (2015). Deep residual learning for image recognition. *arXiv*. Descargado de <https://arxiv.org/abs/1512.03385>
- Hinton, G. E., Srivastava, N., Krizhevsky, A., Sutskever, I., y Salakhutdinov, R. R. (2012). Improving neural networks by preventing co-adaptation of feature detectors. *ArXiv*.
- Hu, J., Shen, L., Albanie, S., Sun, G., y Wu, E. (2020). Squeeze-and-excitation networks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 42(8), 2011–2023. doi: 10.1109/TPAMI.2019.2913372
- Huang, G., Liu, Z., van der Maaten, L., y Weinberger, K. Q. (2018). Densely connected convolutional networks. *arXiv*. Descargado de <https://arxiv.org/abs/1608.06993>
- Ikromjanov, K., Subrata, y cols. (2021). Multi-class classification of histopathology images using fine-tuning techniques of transfer learning. *Journal of Korea Multimedia Society*. (Artscience.kr JAKO202123261931184)
- Ioffe, S., y Szegedy, C. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift.
- Kim, B., Wattenberg, M., Gilmer, J., Cai, C. J., Wexler, J., Viégas, F. B., y Sayres, R. (2017). Interpretability beyond feature attribution: Quantitative testing with concept activation vectors (tcav). En *International conference on machine learning*. Descargado de <https://api.semanticscholar.org/CorpusID:51737170>
- Kingma, D. P., y Ba, J. (2017). Adam: A method for stochastic optimization. *International Conference on Learning Representations*.
- Knab, P., Marton, S., Schlegel, U., y Bartelt, C. (2025). *Which lime should i trust? concepts, challenges, and solutions*. Descargado de <https://arxiv.org/abs/2503.24365>

- LeCun, Y., Bengio, Y., y Hinton, G. (2015). Deep learning. *Nature*, 521, 436-44. doi: 10.1038/nature14539
- Li, Z., Liu, F., Yang, W., Peng, S., y Zhou, J. (2022). A survey of convolutional neural networks: Analysis, applications, and prospects. *IEEE Transactions on Neural Networks and Learning Systems*, 33(12), 6999-7019. doi: 10.1109/TNNLS.2021.3084827
- Liu, S., Kailkhura, B., Loveland, D., y Han, Y. (2019, julio). Generative Counterfactual Introspection for Explainable Deep Learning. *arXiv e-prints*, arXiv:1907.03077. doi: 10.48550/arXiv.1907.03077
- Longo, L., Brcic, M., Cabitza, F., Choi, J., Confalonieri, R., Ser, J. D., ... Stumpf, S. (2024). Explainable artificial intelligence (xai) 2.0: A manifesto of open challenges and interdisciplinary research directions. *Information Fusion*, 106, 102301. Descargado de <https://www.sciencedirect.com/science/article/pii/S1566253524000794> doi: <https://doi.org/10.1016/j.inffus.2024.102301>
- Lundberg, S. M., y Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Proceedings of the 31st international conference on neural information processing systems* (p. 4768-4777). Red Hook, NY, USA: Curran Associates Inc.
- Mitchell, T. M. (1997). *Machine Learning*. New York: McGraw-Hill.
- Montavon, G., Binder, A., Lapuschkin, S., Samek, W., y Müller, K.-R. (2019, 09). Layer-wise relevance propagation: An overview. En (p. 193-209). doi: 10.1007/978-3-030-28954-6_10
- Montavon, G., Orr, G. B., y Müller, K.-R. (2012). *Neural networks: tricks of the trade* (Vol. 7700). Springer.
- Moradi, R., Berangi, R., y Minaei, B. (2020). A survey of regularization strategies for deep models. *Artif. Intell. Rev.*, 53(6). Descargado de <https://doi.org/10.1007/s10462-019-09784-7> doi: 10.1007/s10462-019-09784-7
- Murphy, K. P. (2022). *Probabilistic machine learning: An introduction*. MIT Press. Descargado de probml.ai
- Olah, C., Mordvintsev, A., y Schubert, L. (2017, 11). Feature visualization. *Distill*, 2. doi: 10.23915/distill.00007
- Prince, S. J. (2023). *Understanding deep learning*. MIT press.
- Rabaan, A. A., Bakhrebah, M. A., AlSaihati, H., Alhumaid, S., Alsubki, R. A., Turkistani, S. A., ... Mutair, A. A. (2022). Artificial intelligence for clinical diagnosis and treatment of prostate cancer. *Cancers*, 14(22), 5595. Descargado de <https://doi.org/10.3390/cancers14225595> doi: 10.3390/cancers14225595
- Ribeiro, M. T., Singh, S., y Guestrin, C. (2016). "why should i trust you?": Explaining the predictions of any classifier. En *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining* (p. 1135-1144). New York, NY, USA: Association for Computing Machinery. Descargado de <https://doi.org/>

Bibliografía

- 10.1145/2939672.2939778 doi: 10.1145/2939672.2939778
- Rieger, L., Singh, C., Murdoch, W., y Yu, B. (2020, 13–18 Jul). Interpretations are useful: Penalizing explanations to align neural networks with prior knowledge. En H. D. III y A. Singh (Eds.), *Proceedings of the 37th international conference on machine learning* (Vol. 119, pp. 8116–8126). PMLR. Descargado de <https://proceedings.mlr.press/v119/rieger20a.html>
- Rosenfeld, A. (2021). Better metrics for evaluating explainable artificial intelligence. En *Proceedings of the 20th international conference on autonomous agents and multiagent systems* (p. 45–50). Richland, SC: International Foundation for Autonomous Agents and Multiagent Systems.
- Ross, A., y Doshi-Velez, F. (2018). Improving the adversarial robustness and interpretability of deep neural networks by regularizing their input gradients. *Proceedings of the AAAI Conference on Artificial Intelligence*, 32(1). Descargado de <https://ojs.aaai.org/index.php/AAAI/article/view/11504> doi: 10.1609/aaai.v32i1.11504
- Ross, A. S., Hughes, M. C., y Doshi-Velez, F. (2017). Right for the right reasons: Training differentiable models by constraining their explanations. En *Proceedings of the twenty-sixth international joint conference on artificial intelligence, IJCAI-17* (pp. 2662–2670). Descargado de <https://doi.org/10.24963/ijcai.2017/371> doi: 10.24963/ijcai.2017/371
- Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., y Chen, L.-C. (2018). Mobilenetv2: Inverted residuals and linear bottlenecks. En *2018 IEEE/CVF conference on computer vision and pattern recognition* (p. 4510–4520). doi: 10.1109/CVPR.2018.00474
- Schmidhuber, J. (2015). Deep learning in neural networks: An overview. *Neural Networks*, 61, 85–117. Descargado de <http://dx.doi.org/10.1016/j.neunet.2014.09.003> doi: 10.1016/j.neunet.2014.09.003
- Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., y Batra, D. (2017, Oct). Grad-cam: Visual explanations from deep networks via gradient-based localization. En *Proceedings of the IEEE international conference on computer vision (iccv)*.
- Sevillano-García, I., Luengo, J., y Herrera, F. (2023a). Revel framework to measure local linear explanations for black-box models: Deep learning image classification case study. *International Journal of Intelligent Systems*, 2023(1), 8068569. Descargado de <https://onlinelibrary.wiley.com/doi/abs/10.1155/2023/8068569> doi: <https://doi.org/10.1155/2023/8068569>
- Sevillano-García, I., Luengo, J., y Herrera, F. (2023b). X-shield: Regularization for explainable artificial intelligence. *ArXiv*. doi: <https://doi.org/10.48550/arXiv.2404.0261>
- Shah, S. M. (2024). Gleason grading system [internet].

- (Revisado el 17 de Mayo, 2024; accedido el 25 de Agosto, 2025. Revisado por: VeriMed Healthcare Network, David C. Dugdale, Brenda Conaway y A.D.A.M. Inc.)
- Sharma, S., Sharma, S., y Athaiya, A. (2020). Activation functions in neural networks. *International Journal of Engineering Applied Sciences and Technology*, 04, 310-316. doi: 10.33564/IJEAST.2020.v04i12.054
- Smith, S. L., Kindermans, P.-J., Ying, C., y Le, Q. V. (2018). Don't decay the learning rate, increase the batch size. *International Conference on Learning Representations*.
- Sundararajan, M., Taly, A., y Yan, Q. (2017, 06–11 Aug). Axiomatic attribution for deep networks. En D. Precup y Y. W. Teh (Eds.), *Proceedings of the 34th international conference on machine learning* (Vol. 70, pp. 3319–3328). PMLR. Descargado de <https://proceedings.mlr.press/v70/sundararajan17a.html>
- Tan, M., y Le, Q. V. (2019). Efficientnet: Rethinking model scaling for convolutional neural networks. *International Conference on Machine Learning*. Descargado de <https://arxiv.org/abs/1905.11946>
- Vilone, G., y Longo, L. (2021). Notions of explainability and evaluation approaches for explainable artificial intelligence. *Information Fusion*, 76, 89-106. Descargado de <https://www.sciencedirect.com/science/article/pii/S1566253521001093> doi: <https://doi.org/10.1016/j.inffus.2021.05.009>
- Weber, L., Lapuschkin, S., Binder, A., y Samek, W. (2023). Beyond explaining: Opportunities and challenges of xai-based model improvement. *Information Fusion*, 92, 154-176. Descargado de <https://www.sciencedirect.com/science/article/pii/S1566253522002238> doi: <https://doi.org/10.1016/j.inffus.2022.11.013>
- Woo, S., Debnath, S., Hu, R., Chen, X., Liu, Z., Kweon, I. S., y Xie, S. (2023). Convnext v2: Co-designing and scaling convnets with masked autoencoders. En *2023 IEEE/CVF conference on computer vision and pattern recognition (cvpr)* (p. 16133-16142). doi: 10.1109/CVPR52729.2023.01548
- Wulczyn, E., Nagpal, K., Symonds, M., y et al. (2021). Predicting prostate cancer specific-mortality with artificial intelligence-based gleason grading. *Communications Medicine*, 1, 10. Descargado de <https://doi.org/10.1038/s43856-021-00005-3> doi: 10.1038/s43856-021-00005-3
- Yu, J., Wang, Z., Vasudevan, V., Yeung, L., Seyedhosseini, M., y Wu, Y. (2022). Co-ca: Contrastive captioners are image-text foundation models. *Transactions on Machine Learning Research*. Descargado de <https://openreview.net/forum?id=Ee277P3AYC>